



Phân tích Thảm họa tàu Titanic sử dụng mô hình Machine Learning

Nhóm Thực Hiện

- 3123560073 - Đỗ Duy Quý
- 3123410274 - Lư Hồng Phúc
- 3123410387 - Nguyễn Hữu Tri
- 3123410258 - Lê Thanh Phát

Môn Học

NHẬP MÔN MÁY HỌC

Nhóm 11 - Chiều thứ 7



Các Giai Đoạn Chính Của Dự Án



1. Giới thiệu Bài toán & Mục tiêu



2. Khám phá & Phân tích Dữ liệu (EDA)



3. Phương pháp & Xây dựng Mô hình



4. Kết quả & Đánh giá



5. Kết luận & Hướng phát triển



1. Giới thiệu bài toán và Mục tiêu

Phân Loại Bài Toán

Đây là **bài toán phân loại nhị phân**, nhằm dự đoán khả năng sống sót của mỗi hành khách (0 = tử vong, 1 = sống sót).

Đặc trưng chính:

- **Pclass:** Hạng vé (1, 2, 3).
- **Sex, Age:** Thông tin cá nhân.
- **Embarked:** Cảng xuất phát (C, Q, S).
- **PassengerId:** ID duy nhất, không dùng để dự đoán.

Thách thức dữ liệu: Xử lý dữ liệu thiếu (ví dụ: Age, Cabin) và mất cân bằng lớp (`Survived`).

Tiêu Chí Đánh Giá Mô Hình

Mô hình được đánh giá dựa trên các tiêu chí sau:

- **Accuracy:** Tỷ lệ dự đoán đúng tổng thể.
- **F1-score:** Cân bằng giữa Precision và Recall, phù hợp với dữ liệu mất cân bằng.

Sự kết hợp này đảm bảo đánh giá toàn diện hiệu năng mô hình.

Tổng Quan Về Các Nghiên Cứu Titanic Trước Đây

Độ Chính Xác & Phương Pháp

- Độ chính xác thường đạt 78-94%.
- Các phương pháp phổ biến: Hồi quy Logistic, Cây Quyết định, Rừng ngẫu nhiên, SVM.

Yếu Tố Ảnh Hưởng Chính

- Giới tính (Sex) và Hạng vé (Pclass) có ảnh hưởng lớn nhất.
- Phụ nữ và hành khách hạng cao có tỷ lệ sống sót cao hơn.
- Tuổi (Age) và Căng lên tàu (Embarked) ít nổi bật hơn.

Bài Học & Xu Hướng Nghiên Cứu

- Tiền xử lý dữ liệu (dữ liệu thiếu, mã hóa) và tạo đặc trưng rất quan trọng.
- Tập trung vào hiểu đặc trưng và áp dụng đa dạng mô hình học máy để tìm giải pháp tối ưu.



Hướng Tiếp Cận Của Chúng Tôi



Khám Phá Dữ Liệu (EDA)

Phân tích sâu để hiểu cấu trúc, phân phối và mối quan hệ giữa các đặc trưng.



Tiền Xử Lý Dữ Liệu

Xử lý giá trị thiếu, mã hóa đặc trưng, và tạo các đặc trưng mới để cải thiện chất lượng dữ liệu.



Xây Dựng Mô Hình

Phát triển và huấn luyện các mô hình dự đoán, bao gồm XGBoost, Logistic Regression và Random Forest,...




Đánh Giá, So Sánh Hiệu Suất

Đánh giá hiệu quả của các mô hình thông qua K-Fold Cross-Validation và lựa chọn mô hình tốt nhất.

Titanic - Machine Learning from Disaster

Start here! Predict survival on the Titanic and get familiar with ML basics



Dữ liệu Titanic: Cấu Trúc và Kiểu Dữ Liệu

Nguồn Dữ Liệu

Bộ dữ liệu công khai từ Kaggle, tập trung vào thảm họa Titanic.

Cấu Trúc Dữ Liệu

Tập huấn luyện (**train.csv**): 891 dòng, 12 cột (bao gồm biến mục tiêu).

Tập kiểm tra (**test.csv**): 418 dòng, 11 cột.

Kiểu Dữ Liệu Chính

- Số liên tục (Age, Fare...)
- Categorical có thứ tự (Pclass)
- Categorical không thứ tự (Sex, Embarked)



Phân Tích Dữ Liệu Thiếu và Trùng Lặp

Dữ Liệu Thiếu (Missing Values)

Các cột có giá trị thiếu cần xử lý là: Age, Cabin, và Embarked.

Cabin: thiếu 687/891 giá trị (khoảng 77%)

Age: thiếu 177 giá trị (khoảng 20%)

Cột Cabin có tỷ lệ thiếu dữ liệu cao nhất, đòi hỏi phương pháp xử lý đặc biệt thay vì loại bỏ.

Dữ Liệu Trùng Lặp

Đã kiểm tra và xác nhận **không có dòng dữ liệu trùng lặp** nào trong tập huấn luyện, đảm bảo tính duy nhất của các bản ghi hành khách.



Chiến Lược Xử Lý Giá Trị Thiếu

Việc điền giá trị thiếu cần đảm bảo tính logic và chính xác dựa trên đặc điểm của hành khách và tránh rò rỉ dữ liệu.




Phân Loại & Phương Pháp Xử Lý:

- **Tập huấn luyện (Train):** Các cột có giá trị thiếu bao gồm Age, Cabin, Embarked.
- **Tập kiểm thử (Test):** Các cột có giá trị thiếu bao gồm Age, Cabin, Fare.
- **Cabin:** Thiếu khoảng 77-80% giá trị, do đó rất khó sử dụng hiệu quả cho phân tích định lượng.
- **Age, Embarked, Fare:** Số lượng giá trị thiếu ít hơn, sẽ được điền bằng **giá trị trung vị (median)** hoặc **mốt (mode)** tương ứng.
- **Lưu ý quan trọng:** Cần xử lý tập huấn luyện và tập kiểm thử tách biệt để tránh hiện tượng **rò rỉ dữ liệu (data leakage)**,
đảm bảo tính khách quan của mô hình.

Phân Tích Dữ Liệu Đơn Biến

- Tỷ lệ sống sót:
Mất cân bằng
(38%- 62%)



• Hạng vé
(Pclass):
Đa số thuộc hạng 3

- Tuổi (Age): Phân phối lệch phải, tập trung: 20-40.

- SibSp & Parch: Phần lớn hành khách đi một mình

- Giá vé (Fare): Phân phối lệch phải

Phân Tích Dữ Liệu Đơn Biến

Tỷ lệ sống sót

Dữ liệu mất cân bằng:


38% sống sót,

62% không sống sót.

Cần xử lý để tránh **sai lệch mô hình**.

Hiểu rõ phân phối

Phân tích từng biến giúp có cái nhìn tổng quan, chuẩn bị cho **phân tích đa biến** và **xây dựng mô hình** hiệu quả.





Phân Tích Dữ Liệu Đa Biến

- **PassengerId:**


Tương quan không đáng kể,
loại bỏ khi huấn luyện mô hình.

- **Survived – Pclass (-0.34):**

Hành khách hạng thấp, tỷ lệ sống
sót thấp hơn.

- **Survived – Fare (0.26)**

Giá vé cao, cơ hội sống sót cao hơn.



Phân Tích Dữ Liệu Đa Biến

- **Pclass – Fare (-0.55):**

Hạng thấp, vé rẻ hơn (có thể dư thừa thông tin).

- **SibSp – Parch (0.41):**


Hành khách đi cùng gia đình.

- **Age – Survived (-0.077):**

Tuổi tác ít ảnh hưởng đến sống sót.

- **Age – Pclass (-0.37):**


Hành khách hạng thấp có xu hướng trẻ hơn.



Tương Quan Giữa Các Đặc Trưng

Sex - Pclass & Survived

Đây là hai đặc trưng có tương quan mạnh mẽ nhất với **Survived**. Phụ nữ và trẻ em, đặc biệt ở hạng vé cao, có tỷ lệ sống sót cao hơn rõ rệt.




Tương Quan Giữa Các Đặc Trưng

Sex - Pclass & Survived

Nữ giới có tỷ lệ sống sót cao hơn nam giới trong tất cả các nhóm.


Nam giới chiếm số lượng nhiều hơn và tỷ lệ tử vong cao hơn, đặc biệt ở nhóm 3 (có thể là Pclass 3).




Tương Quan Giữa Các Đặc Trưng

Sex & Pclass & Survived

Nhóm thứ ba có tổng số người nhiều nhất nhưng tỷ lệ sống sót thấp nhất, thể hiện rằng giới tính và nhóm (có thể là hạng) đều ảnh hưởng đến khả năng sống sót.



Tương Quan Giữa Các Đặc Trưng




**Survival rate
theo Deck &
Pclass**

Giúp phát hiện chênh phân bố (ví dụ Deck nào tập trung nhiều hành khách hạng 1) — quan trọng cho EDA và khi phân tích tỷ lệ sống sót



Phân tích các yếu tố quyết định khả năng sống sót



Giới tính và Hạng vé


đóng góp gần **77%** vào khả năng sống sót

Phương pháp và quá trình thử nghiệm

1. Xử Lý Dữ Liệu Thiếu

Tuổi (Age):

Sử dụng giá trị trung vị (median) của nhóm dựa trên tổ hợp Pclass và Sex để điền vào các giá trị thiếu.



Phương pháp và quá trình thử nghiệm

1. Xử Lý Dữ Liệu Thiếu

Cảng Khởi Hành (Embarked):

Điền giá trị thiếu bằng chế độ (mode) của cột, tức là cảng xuất phát phổ biến nhất.


2,4,5,5,4,5
→ 2,4,4,5,5,5
 1 2 3
MODE = 5

Phương pháp và quá trình thử nghiệm

1. Xử Lý Dữ Liệu Thiếu

Giá Vé (Fare):

Điền giá trị thiếu bằng giá trị trung vị (median) của cột



Phương pháp và quá trình thử nghiệm

2. Tạo Đặc Trưng Mới (Feature Engineering)

Kích Thước Gia Đình (FamilySize):

Gộp thông tin về gia đình
(SibSp, Parch) để đo lường
quy mô nhóm đi cùng

$$\text{FamilySize} = \text{SibSp} + \text{Parch} + 1$$

Đi Một Mình (IsAlone):

Xác định rõ những hành khách đi một
mình, vì đây là một trạng thái đặc biệt.

Tạo biến nhị phân, IsAlone = 1
nếu FamilySize == 1

Danh Xưng (Title):

Trích xuất danh xưng
(ví dụ: Mr, Miss, Mrs, Master, Dr)
từ cột Name.

Boong tàu (deck)

Lấy thông tin vị trí cabin, vì vị trí
có thể ảnh hưởng đến khả năng
thoát hiểm.



Phương pháp và quá trình thử nghiệm

3. Quy Trình Thử Nghiệm (Experimentation Pipeline)



Phương pháp: K-fold + GridSearchCV

Hành Trình Tối Ưu Hóa Mô Hình Titanic:
Từ Baseline đến Ensembling

Phương pháp: K-fold + GridSearchCV




Từng iteration của k-fold:
GridSearch thực hiện từng thuật toán với từng bộ parameter




GridSearchCV để chọn thuật toán tốt nhất:

- RandomForest
- SVM
- XGBoost
- LogisticRegression
- DesicionTree


Hành Trình Tối Ưu Hóa Mô Hình Titanic Từ Baseline đến Ensembling




Hành Trình Tối Ưu Hóa Mô Hình Titanic Từ Baseline đến Ensembling




Hành Trình Tối Ưu Hóa Mô Hình Titanic Từ Baseline đến Ensembling




Hành Trình Tối Ưu Hóa Mô Hình Titanic Từ Baseline đến Ensembling




Hành Trình Tối Ưu Hóa Mô Hình Titanic Từ Baseline đến Ensembling



Hành Trình Tối Ưu Hóa Mô Hình Titanic Từ Baseline đến Ensembling



Hành Trình Tối Ưu Hóa Mô Hình Titanic Từ Baseline đến Ensembling



Mô hình tốt nhất: **XGBoost**


- Learning_rate: 0.01
- Max_depth: 7
- N_estimators: 500

Kết quả lần thử nghiệm 3 (V10-Kaggle)

Train score	0.7902
Submit score	0.75837

Hành Trình Tối Ưu Hóa Mô Hình Titanic Từ Baseline đến Ensembling

Lần 3: VotingClassifier + Thêm đặc trưng



Trả lời cho câu hỏi:

Tại sao không sử dụng VotingClassifier cho nhiều thuật toán phân loại khác?

Kết quả lần thử nghiệm 5 (V17-Kaggle)	
Train score	0.7773
Submit score	0.78229



Hành Trình Tối Ưu Hóa Mô Hình Titanic: Từ Baseline đến Ensembling



Lần 1: Baseline

Áp dụng xử lý dữ liệu cơ bản và xây dựng mô hình dự đoán đầu tiên.

Mô hình tốt nhất: **Random Forest**.

Điểm số: **0.7559**.



Lần 3: Ensembling & Đặc Trưng Nâng Cao

Kết hợp sức mạnh của nhiều mô hình bằng **VotingClassifier** và bổ sung các đặc trưng chuyên sâu (IsAlone, male_rich) để đạt hiệu suất tối đa.

Điểm số cao nhất: **0.78229**.



Lần 2: Thêm Đặc Trưng, Thiết Kế Đặc Trưng Sâu Hơn (Title & Deck)

Trích xuất đặc trưng **Title** từ trường Name và **Deck** từ trường Cabin, giúp nắm bắt thông tin chi tiết hơn.

Mô hình tốt nhất: **XGBoost**.

Điểm số: **0.75837** (lưu ý dấu hiệu overfitting).

Phương pháp và quá trình thử nghiệm

4. Đánh Giá Mô Hình (Model Evaluation)

Để đánh giá hiệu suất của mô hình, chúng tôi sử dụng các chỉ số sau:

Độ chính xác (Accuracy)

Tỷ lệ các dự đoán đúng trên tổng số dự đoán.

Điểm F1 (F1-Score)

Trung bình điều hòa của Precision và Recall.

Độ chính xác (Precision)

Khả năng của mô hình không gắn nhãn tích cực cho một mẫu tiêu cực.

Độ bao phủ (Recall)

Khả năng của mô hình tìm thấy tất cả các mẫu tích cực.

ROC-AUC

Đánh giá hiệu suất phân loại ở các ngưỡng khác nhau. Giá trị cao hơn cho thấy khả năng phân loại tốt hơn.

Kết quả và Thảo luận



Mô hình hiệu quả nhất

Mô hình kết hợp (Ensemble) sử dụng **VotingClassifier** với các thuật toán *Random Forest*, *XGBoost*, *SVC*, và *LGBM Classifier* đã cho kết quả tốt nhất trên Kaggle: **0.78229**.



Bài học về Feature Engineering

Việc tạo ra các đặc trưng mới một cách thông minh (như *Deck*, *Title*, *Family_Size*) có tác động lớn đến hiệu suất mô hình, thậm chí còn quan trọng hơn việc chỉ tinh chỉnh tham số.



Vấn đề Overfitting

Trong quá trình thử nghiệm (Lần 3), chúng tôi nhận thấy việc thêm quá nhiều đặc trưng phức tạp có thể dẫn đến **overfitting**, khi mô hình học quá tốt trên tập huấn luyện nhưng dự đoán kém trên dữ liệu mới.



Kết quả và đánh giá

Kết Quả:

- + Lần 3 với **0.7773** trên tập train
- + Lần 3 với **0.78229** trên tập text

Đánh Giá:

- + Mô hình đã cho ra dự đoán đúng khoảng 80%
- + Mới chỉ khai thác và phát hiện được một phần thông in bên trong dữ liệu.
- + Các mô hình và phương pháp làm còn đơn sơ và chưa đi sâu vào tinh chỉnh mô hình phù hợp.

Thử nghiệm	Cải tiến chính	Mô hình tốt nhất	Score (Kaggle)
Lần 1	Baseline: Xử lý dữ liệu cơ bản, xóa Cabin & Name.	Random Forest	0,7559
Lần 2	Tạo đặc trưng Relationship, trích xuất Title & Deck.	XGBoost	0,777537
Lần 3	VotingClassifier (4 mô hình) + Features nâng cao.		0,78229



Kết luận

Dự án đã xây dựng thành công mô hình dự đoán, khẳng định các yếu tố như tầng lớp xã hội, giới tính và gia đình ảnh hưởng trực tiếp đến khả năng sống sót. Kỹ thuật tạo đặc trưng đã hoạt động hiệu quả.

Hướng phát triển

Tối ưu hóa hiệu suất mô hình


Dùng các công cụ tự động như Optuna để tìm bộ tham số tốt nhất

Thử nghiệm mô hình nâng cao

Khám phá các thuật toán mạnh hơn như CatBoost, LightGBM để tăng độ chính xác.

Phân tích chuyên sâu nhóm hành khách

Đi sâu vào các nhóm hành khách cụ thể và dùng SHAP để diễn giải quyết định của mô hình.



Cảm ơn thầy và các bạn
đã lắng nghe

