

Phân tích và dự đoán giá nhà bằng các thuật toán Machine Learning

Thành viên: Lê Thanh Phát, Nguyễn Hữu Tri, Lư Hồng Phúc, Đỗ Duy Quý

Abstract - Phân tích dữ liệu giá nhà là điều cần thiết để hiểu rõ các yếu tố ảnh hưởng đến giá trị bất động sản. Mối tương quan giữa các đặc trưng độc lập và biến mục tiêu đã được quan sát nhằm xác định những yếu tố có thể tác động đến giá bán của ngôi nhà. Trong bài báo này, chúng tôi đã khám phá bộ dữ liệu House Prices - Advanced Regression Techniques từ Kaggle và triển khai các thuật toán học máy gồm XGBoost, Linear Regression và Random Forest, LightGBM, Lasso và Ridge để dự đoán giá bán (SalePrice) của các căn nhà. Một số yếu tố như "OverallQual", "GrLivArea" và "TotalSF" được xác định là có ảnh hưởng then chốt đến giá nhà. Phân tích so sánh giữa các mô hình đã được thực hiện, và các mô hình được đánh giá thông qua nhiều chỉ số đo lường như RMSE (Root Mean Squared Error), MAE (Mean Absolute Error) và R^2 (Coefficient of Determination). Dựa trên kết quả phân tích và đánh giá, XGBoost cho thấy hiệu suất vượt trội hơn so với các mô hình còn lại trong nghiên cứu này.

I. Giới thiệu

Các thuật toán học máy (machine learning algorithms) đã giúp các nhà phân tích dữ liệu, nhà khoa học dữ liệu và kỹ sư dữ liệu khám phá được những hiểu biết sâu sắc từ các dữ liệu thực tế. Một trong những lĩnh vực ứng dụng phổ biến nhất hiện nay là dự đoán giá bất động sản, nơi giá nhà chịu ảnh hưởng của nhiều yếu tố khác nhau như vị trí địa lý, chất lượng xây dựng, diện tích và các đặc trưng tiện nghi. Việc dự đoán chính xác giá nhà không chỉ có ý nghĩa về mặt kinh tế mà còn hỗ trợ trong việc ra quyết định đầu tư, quy hoạch đô thị và định giá tài sản.

Trong bài toán dự đoán giá nhà, dữ liệu được thu thập từ hàng nghìn căn hộ và ngôi nhà với nhiều đặc trưng định lượng và định tính khác nhau. Một trong những bộ dữ liệu nổi tiếng nhất là "House Prices – Advanced Regression Techniques" được công bố trên nền tảng Kaggle, bao gồm hơn 80 đặc trưng liên quan đến cấu trúc, vật liệu và vị trí của căn nhà. Bộ dữ liệu này cung cấp một cơ sở dữ liệu phong phú để nghiên cứu và phát triển các mô hình dự đoán giá nhà hiệu quả.

Một trong những thuật toán học máy mạnh mẽ nhất hiện nay, đạt hiệu suất cao trong các bài toán hồi quy, là Gradient Boosting, đặc biệt là XGBoost và LightGBM. Các thuật toán này nổi bật nhờ khả năng xử lý dữ liệu nhiễu, mối quan hệ phi tuyến và tương tác phức tạp giữa các biến. Trong nhiều năm qua, Gradient Boosting vẫn được xem là phương pháp chủ đạo cho các bài toán học có dữ liệu nhiễu, đặc trưng không đồng nhất và mối quan hệ phức tạp giữa các biến.

Các mô hình học máy đã được ứng dụng rộng rãi trong nhiều lĩnh vực như tài chính, y tế, thương mại điện tử, và đặc biệt là trong dự đoán giá bất động sản. Một số nghiên cứu trước đây đã tiếp cận bài toán này bằng nhiều phương pháp khác nhau. Zhang (2020) đã so sánh hiệu suất giữa các mô hình Linear Regression, Decision Tree và Random Forest, trong đó Random Forest cho kết quả tốt hơn với sai số trung bình nhỏ hơn 10%. Kaggle Notebook của Sunghwan Kim (2022) áp dụng XGBoost và Lasso Regression, đạt điểm số RMSE = 0.122 trên tập kiểm thử. Một số tác giả khác sử dụng LightGBM và Stacking Ensemble để cải thiện hiệu năng, cho thấy sự kết hợp giữa các mô hình boosting mang lại độ chính xác cao hơn đáng kể.

Từ các kết quả này, có thể thấy thuật toán Gradient Boosting (đặc biệt là XGBoost và LightGBM) vẫn giữ vai trò chủ đạo trong các bài toán hồi quy phức tạp, nơi dữ liệu chứa nhiều đặc trưng không đồng nhất và mối quan hệ phi tuyến giữa các biến độc lập và biến mục tiêu (SalePrice).

Trong nghiên cứu này, chúng tôi sẽ khám phá bộ dữ liệu House Prices và triển khai nhiều thuật toán học máy khác nhau, bao gồm XGBoost, LightGBM, Linear Regression, Lasso, Ridge, và Gradient Boosting để dự đoán giá bán nhà. Một số yếu tố như "OverallQual" (chất lượng tổng thể), "GrLivArea" (diện tích sống) và "TotalSF" (tổng diện tích) được xác định là có ảnh hưởng then chốt đến giá nhà. Phân tích so sánh giữa các mô hình đã được thực hiện, và các mô hình được đánh giá thông qua nhiều chỉ số đo lường như RMSE (Root Mean Squared Error), MAE (Mean Absolute Error) và R^2 (Coefficient of Determination).

Phần còn lại của bài báo được cấu trúc như sau:

- Phần II:** Phân tích bài toán và dữ liệu
- Phần III:** Phương pháp và quá trình thử nghiệm
- Phần IV:** Kết quả và đánh giá
- Phần V:** Hướng cải tiến mô hình.
- Phần VI:** Tài liệu tham khảo.

II. Phân tích bài toán

1. Phân tích bối cảnh và mục tiêu

1.1. Phân tích bối cảnh và mục tiêu

Dự đoán giá nhà là một trong những bài toán quan trọng và phổ biến nhất trong lĩnh vực bất động sản và machine learning.

Từ dữ liệu về các căn nhà được công bố, bài toán đặt ra là dự đoán giá bán của một căn nhà dựa trên các đặc trưng về cấu trúc, vị trí, chất lượng và tiện nghi.

Mục tiêu: Xây dựng mô hình học máy để dự đoán biến 'SalePrice' (giá bán nhà) từ các đặc trưng đầu vào bao gồm: OverallQual (chất lượng tổng thể), GrLivArea (diện tích sống), TotalBsmntSF (tổng diện tích tầng hầm), LotArea (diện tích lô đất), Neighborhood (khu vực), HouseStyle (kiểu nhà), YearBuilt (năm xây dựng), GarageArea (diện tích garage), TotalSF (tổng diện tích), và hơn 70 đặc trưng khác liên quan đến cấu trúc, vật liệu, điều kiện và vị trí của căn nhà.

1.2. Dạng bài toán

Dữ liệu thiếu: Một số cột như PoolQC, MiscFeature, Alley thiếu hơn 80% trong tổng số dữ liệu, đây là một thách thức lớn; LotFrontage, GarageYrBlt, MasVnrArea có nhiều giá trị null cần xử lý; các biến liên quan đến Garage và Basement cũng có nhiều giá trị thiếu. Tính không tuyến tính: Giá nhà không phụ thuộc tuyến tính vào từng đặc trưng mà phụ thuộc vào sự kết hợp của chúng (ví dụ: OverallQual cao, GrLivArea lớn và Neighborhood tốt thì giá cao hơn nhiều so với tổng của từng yếu tố). Phân phối lệch: Biến mục tiêu SalePrice có phân phối lệch phải, với nhiều nhà giá thấp và ít nhà giá rất cao, do đó biến đổi như log transformation. Outliers: Dữ liệu chứa nhiều giá trị ngoại lai trong các biến như GrLivArea, LotArea và SalePrice, có thể ảnh hưởng đến hiệu suất mô hình. Nhiều đặc trưng phi số: Cần mã hóa các đặc trưng phân loại như Neighborhood, HouseStyle, MSZoning, SaleCondition, Foundation và nhiều đặc trưng khác.

1.3. Thách thức chính

Đây là một bài toán hồi quy (regression) trong học máy có giám sát (supervised learning). Đầu vào (Input features): thông tin về các đặc trưng của căn nhà bao gồm đặc điểm cấu trúc, vị trí địa lý, chất lượng, điều kiện và tiện nghi. Đầu ra (Label): giá bán nhà (SalePrice) - một giá trị số liên tục tính bằng USD. Mục tiêu huấn luyện: tìm hàm ánh xạ $f(X) \rightarrow y$, sao cho mô hình dự đoán giá nhà chính xác nhất với sai số nhỏ nhất, tối ưu hóa các chỉ số đánh giá như RMSE (Root Mean Squared Error), MAE (Mean Absolute Error) và R^2 (Coefficient of Determination).

2. Data Description (Mô tả dữ liệu)

2.1 Nguồn Dữ liệu

Bộ dữ liệu được sử dụng là House Prices – Advanced Regression Techniques (Kaggle). Tập huấn luyện (train.csv) và tập kiểm thử (test.csv) có thể truy cập tại: <https://www.kaggle.com/c/house-prices-advanced-regression-techniques>.

Tập huấn luyện (train.csv) bao gồm 1.460 mẫu, trong khi tập kiểm thử (test.csv) gồm 1.459 mẫu. Mỗi dòng dữ liệu đại diện cho một căn nhà, với hơn 80 đặc trưng (features) mô tả chi tiết về cấu trúc, vật liệu xây dựng, tình trạng sử dụng, và các tiện nghi xung quanh. Dữ liệu bao gồm cả biến số (numeric) và biến phân loại (categorical), trong đó biến mục tiêu là SalePrice – giá bán thực tế của căn nhà (đơn vị: USD).

2.2 Cấu Trúc Dữ Liệu

Các cột (features) chính trong dữ liệu gồm:

Tên cột	Kiểu dữ liệu	Mô tả
SalePrice	float	Giá bán của căn nhà (biến mục tiêu)
OverallQual	int (1–10)	Chất lượng tổng thể của vật liệu và hoàn thiện
GrLivArea	int	Diện tích sinh hoạt chính (trên mặt đất)
GarageCars	int	Số chỗ để xe trong gara
TotalBsmntSF	int	Tổng diện tích tầng hầm
1stFlrSF	int	Diện tích tầng 1
FullBath	int	Số phòng tắm đầy đủ
YearBuilt	int	Năm xây dựng căn nhà
YearRemodAdd	int	Năm sửa chữa hoặc cải tạo gần nhất
GarageArea	int	Diện tích gara (feet vuông)
LotArea	int	Diện tích lô đất
Neighborhood	string	Khu dân cư hoặc vị trí địa lý của căn nhà

2.3. Đặc điểm nổi bật của dữ liệu


Dữ liệu chứa một số giá trị thiếu, đặc biệt xuất hiện nhiều ở các cột như PoolQC, Alley, Fence, FireplaceQu và MiscFeature, do đó cần được xử lý trước khi huấn luyện mô hình. Một số biến, bao gồm SalePrice và các biến diện tích như GrLivArea, LotArea, có phân phối lệch phải, nên thực hiện log-transform để ổn định phân phối.

Ngoài ra, các biến OverallQual, GrLivArea, GarageCars, TotalBsmtSF và YearBuilt có tương quan mạnh với giá bán, đóng vai trò quan trọng trong dự đoán. Dữ liệu cũng đa dạng về loại đặc trưng, bao gồm cả giá trị số và phân loại, đòi hỏi áp dụng các kỹ thuật mã hóa và chuẩn hóa phù hợp trước khi đưa vào mô hình.


3. Phân Tích Dữ Liệu

3.1 Phân tích dữ liệu thiếu

Kết quả thống kê cho thấy một số cột trong cả tập huấn luyện (train) và tập kiểm thử (test) chứa giá trị bị thiếu, với mức độ khác nhau giữa các đặc trưng. Cụ thể, trong tập huấn luyện, các cột như PoolQC, MiscFeature, Alley, Fence, MasVnrType, FireplaceQu, v.v. đều có giá trị bị thiếu và cần được xử lý trước khi đưa vào mô hình.



Tập kiểm thử (test) có giá trị thiếu ở nhiều cột tương tự, cùng với một số cột bổ sung như TotalBsmtSF, BsmtUnfSF, BsmtFinSF2, BsmtFinSF1, KitchenQual, GarageArea, GarageCars, SaleType.



Trong tập huấn luyện, giá bán trung bình của các căn nhà vào khoảng 180.921 USD, với mức thấp nhất khoảng 34.900 USD và cao nhất vượt 755.000 USD. “OverallQual” có xu hướng tỷ lệ thuận với giá bán, khi những căn nhà có chất lượng cao (từ 8–10) thường có giá gấp 2–3 lần so với nhóm trung bình.


Phần lớn các căn nhà có diện tích sinh hoạt (GrLivArea) nằm trong khoảng 1.000–2.500 ft², chiếm khoảng 70% tổng số mẫu trong dữ liệu. Đồng thời, khoảng 50% số căn nhà được xây dựng trong giai đoạn 1950–2000, cho thấy dữ liệu có sự đa dạng đáng kể về thời gian xây dựng.

3.2 Phân tích đơn biến

	count	mean	std	min	25%	50%	75%	max	Skewness	Kurtosis
Id	1460.000000	730.500000	421.610000	1.000000	365.750000	730.500000	1095.250000	1460.000000	0.000000	-1.200000
MSSubClass	1460.000000	56.897000	42.301000	20.000000	20.000000	50.000000	70.000000	190.000000	1.480000	1.580000
LotFrontage	1201.000000	70.050000	24.285000	21.000000	59.000000	69.000000	80.000000	313.000000	2.164000	17.453000
LotArea	1460.000000	10516.828000	9981.265000	1300.000000	7553.500000	9478.500000	11601.500000	215245.000000	12.208000	203.243000
OverallQual	1460.000000	6.099000	1.383000	1.000000	5.000000	6.000000	7.000000	10.000000	6.217000	0.096000
OverallCond	1460.000000	5.575000	1.113000	1.000000	5.000000	5.000000	6.000000	9.000000	0.693000	1.106000
YearBuilt	1460.000000	1971.268000	30.203000	1872.000000	1954.000000	1973.000000	2000.000000	2010.000000	-0.613000	-0.480000
YearRemodAdd	1460.000000	1984.866000	20.645000	1950.000000	1967.000000	1994.000000	2004.000000	2010.000000	-0.594000	1.272000
MasVnrArea	1452.000000	103.685000	181.066000	0.000000	0.000000	0.000000	166.000000	1600.000000	2.660000	10.002000
BsmtFinSF1	1460.000000	443.640000	456.098000	0.000000	0.000000	383.500000	712.250000	5644.000000	1.686000	11.118000
BsmtFinSF2	1460.000000	46.549000	161.319000	0.000000	0.000000	0.000000	0.000000	1474.000000	4.255000	20.113000
BsmtUnfSF	1460.000000	567.240000	441.867000	0.000000	223.000000	477.500000	808.000000	2336.000000	0.500000	0.475000
TotalBsmtSF	1460.000000	1057.429000	438.705000	0.000000	795.750000	991.500000	1298.250000	6110.000000	1.524000	13.250000
1stFlrSF	1460.000000	1162.627000	386.588000	334.000000	882.000000	1087.000000	1391.250000	4692.000000	1.377000	5.746000
2ndFlrSF	1460.000000	346.992000	436.528000	0.000000	0.000000	0.000000	728.000000	2065.000000	0.813000	-0.553000

Bảng thống kê mô tả dữ liệu

Bảng thống kê mô tả cho thấy các biến số trong tập dữ liệu có sự phân tán và chênh lệch đáng kể. Ví dụ, biến LotArea có giá trị trung bình khoảng 10.516 ft², nhưng giá trị lớn nhất lên tới 215.245 ft², kèm theo độ lệch chuẩn cao (9.981 ft²) và độ lệch phải cực lớn (Skewness = 12,21; Kurtosis = 203,24). Điều này phản ánh sự tồn tại của nhiều giá trị ngoại lệ, do đó cần thực hiện log-transform hoặc chuẩn hóa trước khi huấn luyện mô hình. Các biến diện tích khác như BsmtFinSF1, TotalBsmtSF, 1stFlrSF và MasVnrArea cũng có độ lệch phải cao (Skewness > 1), cho thấy phần lớn các căn nhà có diện tích nhỏ, trong khi chỉ một số ít có diện tích rất lớn.



Biểu đồ Histogram thể hiện phân phối của biến SalePrice

Biểu đồ cho thấy phân phối của SalePrice lệch phải (right-skewed) — phần lớn giá nhà tập trung trong khoảng 100.000–250.000 USD, trong khi chỉ có một số ít trường hợp có giá cao vượt trội trên 400.000 USD. Điều này cho thấy dữ liệu không tuân theo phân phối chuẩn, và tồn tại một số ngoại lệ (outliers) ở nhóm nhà cao cấp, những giá trị này có thể xem xét xóa bỏ hoặc biến đổi phù hợp hơn với dữ liệu hư có thể thay thế chúng bằng IQR trên, được thể hiện trong biểu đồ boxplot ở dưới, giúp cho model học tốt hơn và không bị overfittint với các outlier này. Việc biến đổi **log(SalePrice)** có thể được xem xét để làm giảm độ lệch và giúp mô hình hồi quy hoạt động hiệu quả hơn và hiệu suất huấn luyện tốt hơn.




Biểu đồ BoxPlot thể hiện phân phối của biến SalePrice

Kết quả cho thấy phân phối dữ liệu bị lệch phải rõ rệt, thể hiện qua việc phân hộp nằm gần đáy trong khi các điểm ngoại lệ (outliers) xuất hiện dày đặc ở phía trên


Khoảng tứ phân vị (IQR - Interquartile Range): Phần "hộp" kéo dài từ khoảng 100,000 đến 300,000, cho thấy 50% giá nhà tập trung trong khoảng này.

Các mô hình dự đoán giá nhà có thể bị ảnh hưởng bởi các outlier này → cần cân nhắc loại bỏ hoặc điều chỉnh.



Biểu đồ biến phân loại của Neighborhood

Biến Neighborhood là biến phân loại dạng danh mục, phân bố không đồng đều. Trong đó, khu NAmes chiếm tỷ lệ cao nhất (21.7%), tiếp theo là CollgCr (14.5%) và OldTown (10.9%), cho thấy dữ liệu tập trung chủ yếu ở một số khu vực nhất định.



Biểu đồ biến phân loại của HouseStyle

Biến HouseStyle là biến phân loại danh mục thể hiện kiểu thiết kế của ngôi nhà, bao gồm số tầng và tình trạng hoàn thiện của tầng. Phân bố biến này không đồng đều, trong đó kiểu 1Story chiếm tỷ lệ cao nhất (49,7%), tiếp theo là 2Story (30,5%) và 1.5Fin (10,5%). Các kiểu còn lại như SLvl, SFoyer, 1.5Unf, 2.5Unf và 2.5Fin chiếm dưới 5% dữ liệu. Điều này cho thấy tập dữ liệu tập trung chủ yếu vào các ngôi nhà một và hai tầng, phản ánh xu hướng kiến trúc phổ biến tại khu vực nghiên cứu. Tuy nhiên, sự mất cân bằng này có thể ảnh hưởng đến việc huấn luyện mô hình, cần được xem xét khi mã hóa dữ liệu phân loại.


3.3 Phân tích đơn biến

	Feature	Correlation	AbsCorr
0	OverallQual	0.791000	0.791000
1	GrLivArea	0.708600	0.708600
2	GarageCars	0.640400	0.640400
3	GarageArea	0.623400	0.623400
4	TotalBsmtSF	0.613600	0.613600
5	1stFlrSF	0.605900	0.605900
6	FullBath	0.560700	0.560700
7	TotRmsAbvGrd	0.533700	0.533700
8	YearBuilt	0.522900	0.522900
9	YearRemodAdd	0.507100	0.507100

Top 10 biến có tương quan cao nhất với giá nhà (SalePrice)

Kết quả phân tích tương quan cho thấy các biến có mối quan hệ tuyến tính dương mạnh với SalePrice, nổi bật nhất là OverallQual ($r = 0.79$) và GrLivArea ($r = 0.71$). Điều này cho thấy chất lượng tổng thể của ngôi nhà và diện tích sử dụng là những yếu tố quyết định chính đến giá bán.

Ngoài ra, các biến liên quan đến garage, diện tích tầng hầm, số phòng tắm và năm xây dựng cũng có ảnh hưởng đáng kể, phản ánh xu hướng giá nhà tăng theo quy mô, tiện nghi và độ mới của công trình.



Biểu đồ Scatter Plot của 6 feature có liên quan nhất

SalePrice vs OverallQual: OverallQual càng cao nên SalePrice càng cao. Phạm vi giá tăng đáng kể từ chất lượng 5 lên 10. Có outliers ở chất lượng cao (9-10) với giá >600k


SalePrice vs GrLivArea: Diện tích càng lớn → Giá càng cao (relationship rất rõ). Có 2 outliers nghiêm trọng: GrLivArea > 4000 sqft nhưng SalePrice < 200k (bất thường!). Có thể là lỗi dữ liệu hoặc nhà có vấn đề đặc biệt

SalePrice vs GarageCars: Số xe garage càng nhiều → Giá có xu hướng cao hơn. Phạm vi giá rất rộng ở mỗi giá trị (ví dụ: 2 cars có giá từ 50k đến 600k). Có outliers ở 3 cars với giá rất cao (>600k)

SalePrice vs GarageArea: Diện tích gara (GarageArea) lớn có xu hướng liên quan đến giá bán cao hơn, nhưng mối quan hệ này không quá chặt chẽ. Giá bán trong mỗi mức diện tích vẫn dao động khá rộng, và tồn tại một số giá trị ngoại lệ, đặc biệt ở các căn có GarageArea > 1.200 ft² với giá bán rất cao.

SalePrice vs TotalBsmstSF (Tổng diện tích tầng hầm): Diện tích tầng hầm lớn thường có xu hướng đi kèm với giá bán cao hơn. Tuy nhiên, khoảng 20–30% số căn nhà không có tầng hầm (TotalBsmstSF = 0), và phạm vi giá bán ở các mức diện tích tầng hầm vẫn rất rộng, cho thấy mối quan hệ không hoàn toàn tuyến tính.

SalePrice vs 1stFlrSF (Diện tích tầng 1): Diện tích tầng 1 (1stFlrSF) lớn thường đi kèm với giá bán cao hơn, mối quan hệ này tương tự như với GrLivArea vì tầng 1 thường chiếm phần lớn diện tích sinh hoạt. Tuy nhiên, tồn tại một số giá trị ngoại lệ, đặc biệt ở những căn có 1stFlrSF > 3.000 ft² với giá bán rất cao, vượt 700.000 USD.



Biểu đồ hộp (box plots)

SalePrice theo MSZoning (Phân vùng đô thị): Phân tích theo MSZoning cho thấy loại khu vực có ảnh hưởng rõ rệt đến giá bán nhà. Cụ thể, khu vực RL (Residential Low Density) có giá trung vị khoảng 180k USD, phạm vi rộng từ 30k đến 630k USD và nhiều giá trị ngoại lệ cao trên 600k USD, đồng thời là loại khu vực phổ biến nhất. Khu vực RM (Residential Medium Density) có giá trung vị thấp hơn, khoảng 130k USD, với ít giá trị ngoại lệ hơn. Nhóm C (Commercial, tất cả) có giá trung vị thấp nhất, khoảng 70k USD, phạm vi hẹp và biến động ít. Ngược lại, khu vực FV (Floating Village) có giá trung vị cao nhất, khoảng 220k USD, với phạm vi giá trung bình, còn RH (Residential High Density) có giá trung vị khoảng 130k USD nhưng phạm vi hẹp nhất. Những kết quả này cho thấy MSZoning là một yếu tố quan trọng ảnh hưởng đến giá bán nhà.

SalePrice theo Street (Loại đường): Phân tích theo loại đường (Street) cho thấy các căn nhà có đường Pave (nhựa) có giá trung vị khoảng 165k USD, với phạm vi rộng và nhiều giá trị ngoại lệ cao, đồng thời chiếm đa số trong dữ liệu. Ngược lại, các căn nhà có đường Grvl (sỏi) có giá trung vị khoảng 120k USD, thấp hơn Pave, phạm vi hẹp và ít giá trị ngoại lệ, nhưng số lượng rất ít. Điều này cho thấy dữ liệu bị imbalanced nghiêm trọng, với Pave áp đảo so với Grvl.

SalePrice theo Alley (Hẻm/Ngõ): Phân tích theo loại ngõ (Alley) cho thấy các căn nhà có ngõ Grvl (sỏi) có giá trung vị khoảng 120k USD, phạm vi trung bình và số lượng rất ít. Trong khi đó, các căn nhà có ngõ Pave (nhựa) có giá trung vị cao hơn đáng kể, khoảng 170k USD, với phạm vi rộng và nhiều giá trị ngoại lệ cao trên 200k USD, nhưng cũng chiếm số lượng ít. Kết quả này phản ánh thực tế rằng khoảng 93% mẫu không có ngõ, tức phần lớn các căn nhà đều không có alley.

SalePrice theo LotShape (Hình dạng lô đất): Phân tích theo hình dạng lô đất (LotShape) cho thấy các căn nhà có lô Reg (Regular – hình chữ nhật) có giá trung vị khoảng 170k USD, phạm vi rộng nhất và nhiều giá trị ngoại lệ, đồng thời chiếm đa số mẫu.

Các loại lô bất thường IR1, IR2, IR3 có giá trung vị tương tự nhau, khoảng 200k USD, trong đó IR2 cao nhất khoảng 210k USD, nhưng phạm vi hẹp hơn so với Reg. Kết quả này cho thấy ảnh hưởng của LotShape đến giá bán là yếu, vì sự chênh lệch về median giữa các loại lô không nhiều.

SalePrice theo LandContour (Địa hình): Phân tích theo dạng địa hình lô đất (LandSlope) cho thấy các căn nhà trên lô Lvl (Level – bằng phẳng) có giá trung vị khoảng 165k USD, với phạm vi rộng, nhiều giá trị ngoại lệ và chiếm đa số mẫu. Lô Bnk (Banked – dốc có bờ) có giá trung vị thấp hơn một chút, khoảng 155k USD, phạm vi hẹp và ít giá trị ngoại lệ. Trong khi đó, các lô Low (Depression) có giá trung vị khoảng 180k USD và HLS (Hillside – sườn đồi) có giá trung vị khoảng 210k USD, cao nhất trong các loại, với phạm vi trung bình. Kết quả này cho thấy các lô HLS và Low có giá cao hơn, điều này có ý nghĩa đối với giá bán nhà.

SalePrice theo Utilities (Tiện ích công cộng): Phân tích theo hệ thống cấp nước (Utilities) cho thấy các căn nhà có AllPub (đầy đủ tiện ích) có giá trung vị khoảng 165k USD, phạm vi rộng, nhiều giá trị ngoại lệ và chiếm gần như 100% tổng số mẫu. Ngược lại, các căn nhà thuộc NoSeWa (không có nước/cống) chỉ có 1–2 mẫu, thể hiện sự imbalanced cực kỳ nghiêm trọng. Do đó, feature này nên được loại bỏ trước khi huấn luyện mô hình.

III. Phương pháp và quá trình thử nghiệm

A. Phương pháp

Phương pháp nghiên cứu tập trung vào việc xây dựng và tối ưu mô hình dự đoán giá nhà thông qua quy trình lặp cải tiến. Trọng tâm là xử lý dữ liệu đầu vào, bao gồm làm sạch, xử lý ngoại lệ, bổ sung đặc trưng mới và mã hóa – chuẩn hóa biến. Song song, nhóm nghiên cứu kết hợp nhiều mô hình học máy (tuyến tính và phi tuyến) và áp dụng phương pháp Stacking Ensemble để nâng cao độ chính xác. Toàn bộ quy trình hướng đến tối ưu cả chất lượng đặc trưng lẫn hiệu năng mô hình, giúp cải thiện đáng kể kết quả dự đoán trên tập kiểm định.

B. Quá trình thử nghiệm

Quá trình thử nghiệm mô hình được thực hiện qua nhiều phiên bản, từ việc thiết lập nền tảng cơ bản đến việc áp dụng các kỹ thuật học máy nâng cao.

Chúng tôi khởi động quá trình thử nghiệm bằng việc thiết lập một mô hình cơ sở (baseline). Ở giai đoạn này, chiến lược xử lý dữ liệu được giữ ở mức đơn giản nhất: các giá trị thiếu (NaN) chỉ được điền bằng các giá trị đại diện như "Missing" hoặc 0. Trọng tâm chính là đánh giá hiệu suất của hai thuật toán học máy cây phổ biến: LightGBM và XGBoost.

Model	MAE	RMSE	RMSLE
LightGBM	16651.2861	28387.948	0.141144
XGBoost	14943.0957	24586.148	0.139212
Random Forest	17114.3742	29605.130	0.153763
CatBoost	16274.3968	26992.278	0.137384

Sau khi thực hiện điều chỉnh siêu tham số cơ bản, mô hình XGBoost đã nhanh chóng thiết lập một ngưỡng hiệu suất ban đầu với chỉ số lỗi RMSLE là 0.139212, nhỉnh hơn đôi chút so với LightGBM. Kết quả này không chỉ cung cấp một điểm tham chiếu mà còn khẳng định khả năng ban đầu của các mô hình cây trong việc nắm bắt mối quan hệ của dữ liệu.

Đánh giá: Hiệu suất này được xem là chấp nhận được cho một mô hình cơ sở nhưng cho thấy rõ ràng tiềm năng cải thiện lớn thông qua việc xử lý các giá trị thiếu (NaN) một cách hợp lý và phát triển các đặc trưng mới.

Nhận thấy rằng chất lượng dữ liệu thô là yếu tố giới hạn lớn nhất, chúng tôi chuyển sang giai đoạn làm sạch chuyên sâu. Phiên bản 2 tập trung vào việc loại bỏ các điểm dữ liệu bất thường (outliers) rõ ràng—những ngôi nhà có diện tích ở quá lớn nhưng giá bán lại thấp—nhằm đảm bảo mô hình không bị lệch lạc. Đồng thời, chúng tôi áp dụng phép biến đổi logarit (np.log1p) cho biến mục tiêu (SalePrice) để giảm độ lệch.

Model	MAE	RMSE	RMSLE
LightGBM	0.085108	0.130446	0.010363
XGBoost	0.079704	0.120777	0.009576
CatBoost	0.08064	0.117019	0.009285

Trong phiên bản này, chúng tôi tập trung vào việc làm sạch dữ liệu. Việc loại bỏ các điểm dữ liệu bất thường và áp dụng phép biến đổi logarit cho biến mục tiêu đã cải thiện đáng kể phân phối dữ liệu, giúp mô hình học tập hiệu quả hơn. Sự ra đời của mô hình CatBoost với các đặc trưng kỹ thuật cơ bản đã đạt chỉ số RMSLE rất thấp (tuy nhiên chỉ trên tập huấn luyện).

Đánh giá: Mặc dù kết quả về mặt số học rất tích cực, độ chính xác cao bất thường này trên tập huấn luyện cho thấy nguy cơ overfitting (quá khớp). Phiên bản này nhấn mạnh nhu cầu chuyển sang một chiến lược đánh giá vững vàng hơn, cụ thể là Cross-Validation (CV), để đo lường khả năng tổng quát hóa của mô hình.

Chúng tôi đã tiến hành xử lý ngoại lệ một cách chuyên sâu hơn, rà soát lại và loại bỏ các điểm dữ liệu bất thường có khả năng làm sai lệch quá trình học của mô hình. Cùng với đó, việc xử lý giá trị bị thiếu được thực hiện cẩn thận, đảm bảo mọi khía cạnh của dữ liệu đều được điền đầy đủ và chính xác, sử dụng các phương pháp điền hợp lý cho cả biến định tính và định lượng.

Model	MAE	RMSE	RMSLE
LightGBM	0.078405	0.115593	0.009102
XGBoost	0.074114	0.110397	0.008675
Random Forest	0.08384	0.123675	0.009751
CatBoost	0.076399	0.10998	0.008657

Phiên bản 3 đã thành công trong việc chuyển đổi trọng tâm từ việc tăng độ phức tạp của đặc trưng sang việc tăng cường độ vững vàng của thuật toán thông qua tối ưu hóa siêu tham số và giới thiệu chiến lược kết hợp mô hình sơ khai. Những nỗ lực này đã tạo ra một nền tảng hiệu suất ổn định và đáng tin cậy, làm cơ sở vững chắc để tiếp tục mở rộng bộ đặc trưng một cách an toàn hơn trong các phiên bản tiếp theo.

Phiên bản 4 là sự tổng hợp và tinh chỉnh của tất cả các chiến lược xử lý dữ liệu trước đó, với mục tiêu xây dựng bộ đặc trưng mạnh mẽ và toàn diện nhất. Chúng tôi áp dụng quy tắc loại bỏ outliers nghiêm ngặt hơn và triển khai chiến lược điền giá trị thiếu (missing values) chi tiết hóa, ví dụ: sử dụng phương pháp điền theo thuộc tính (ví dụ: điền 'None' cho các cột liên quan đến hầm hoặc gara, và điền theo Mode/Median cho các cột khác).

Model	MAE	RMSE	RMSLE
LightGBM	0.080181	0.115668	0.009109
XGBoost	0.07874	0.118302	0.009301
Random Forest	0.083906	0.124437	0.009813
CatBoost	0.077502	0.110046	0.008636

Bộ đặc trưng được mở rộng đáng kể với nhiều biến nhị phân mới (HasBasement, IsHomeNew) và áp dụng cả hai kỹ thuật mã hóa thứ tự (Ordinal Encoding) và mã hóa One-Hot cho các biến phân loại. Mặc dù sự phức tạp trong xử lý dữ liệu tăng lên, hiệu suất của các mô hình đơn lẻ như LightGBM và XGBoost vẫn giữ ổn định (với RMSE dao động khoảng 0.115). Điều này cho thấy các mô hình đơn lẻ đã đạt đến giới hạn hiệu suất của chúng.

Đánh giá: Các mô hình đơn lẻ như LightGBM đã được tối ưu hóa tốt (RMSLE = 0.1157 trên CV), nhưng dường như đã đạt đến giới hạn hiệu suất của chúng. Sự khác biệt nhỏ về hiệu suất giữa các mô hình mạnh như LightGBM và XGBoost trong phiên bản này gợi ý rằng bước tiếp theo cần phải là khai thác sức mạnh tổng hợp của nhiều mô hình thay

Sau khi đã tối ưu hóa triệt để các mô hình đơn lẻ, chúng tôi nhận ra cần phải chuyển sang chiến lược học tổng hợp (Ensemble Learning). Trong Phiên bản 5, chúng tôi thử nghiệm các kỹ thuật như Averaging Models và Stacking Averaged Models (kết hợp các dự đoán từ Lasso, ElasticNet, LightGBM và CatBoost). Kỹ thuật Stacking đã cho thấy ưu thế vượt trội với chỉ số RMSE CV là 0.1121, chứng tỏ khả năng giảm phương sai và cải thiện độ vững của dự đoán.

Model	RMSE
LightGBM	0.07348583
XGBoost	0.08639715
Stacking	0.07950309
CatBoost	0.03260942
Enet	0.10574089

Phiên bản 5 đánh dấu sự chuyển đổi chiến lược sang Ensemble Learning. Phương pháp Stacking Averaged Models đã chứng tỏ ưu thế vượt trội, đạt chỉ số RMSE CV là 0.1121, vượt qua tất cả các mô hình đơn lẻ trước đó. Điều này xác nhận rằng việc kết hợp các mô hình có độ lệch khác nhau (ví dụ: mô hình tuyến tính như Lasso và mô hình cây như CatBoost) giúp giảm thiểu lỗi tổng thể.

Cuối cùng, Phiên bản 6 được tạo ra để thực hiện sự tinh chỉnh cuối cùng cho toàn bộ hệ thống. Chúng tôi tập trung vào việc xử lý các giá trị thiếu phức tạp bằng các phương pháp thống kê nâng cao (như điền thiếu LotFrontage bằng median của nhóm Neighborhood tương ứng) và loại bỏ các đặc trưng có tỷ lệ giá trị 0 quá cao để tránh overfitting. Đỉnh điểm là việc áp dụng một kỹ thuật kết hợp có trọng số (Weighted Ensemble): kết hợp mô hình Stacking (70%), CatBoost (15%) và ElasticNet (15%). Dù kết quả CV có chút dao động, phương pháp này đã đạt được chỉ số lỗi RMSLE thấp nhất trên tập huấn luyện là 0.07012, thể hiện một mô hình cực kỳ hiệu quả và sẵn sàng cho việc dự đoán cuối cùng.

Model	RMSE
LightGBM	0.070952045
XGBoost	0.08470602
Stacking	0.0724235
CatBoost	0.03081691
Enet	0.10899926

Phiên bản 6 là bước cuối cùng trong việc tinh chỉnh toàn bộ hệ thống. Chúng tôi thực hiện các chỉnh sửa nhỏ nhưng quan trọng về mặt xử lý dữ liệu (như điền thiếu chi tiết hơn) và áp dụng một kỹ thuật Weighted Ensemble có trọng số tối ưu. Mặc dù kết quả CV không thay đổi nhiều so với V5, mô hình này đã đạt được chỉ số RMSLE thấp nhất trên tập huấn luyện là 0.07012, cho thấy sự tối ưu hóa tuyệt vời của bộ tham số cuối cùng, và được chọn làm mô hình dự đoán chính thức.

IV. Kết quả và đánh giá

Mặc dù các phiên bản cải tiến đã giúp hệ thống đạt được độ chính xác cao và ổn định, ta có thể đánh giá rằng mô hình vẫn mới chỉ khai thác và phát hiện được một phần thông tin bên trong dữ liệu. Sự thiếu sót lớn nhất nằm ở khả năng hiểu rõ bối cảnh kinh tế vĩ mô và lịch sử thị trường tại thời điểm giao dịch, dẫn đến việc mô hình chưa thể đánh giá và liên kết dữ liệu tốt hơn với các yếu tố ngoại sinh chi phối giá nhà (ví dụ: quy hoạch đô thị, biến động lãi suất). Hơn nữa, các mô hình và phương pháp làm còn đơn sơ và chưa đi sâu vào tinh chỉnh phù hợp; hệ thống vẫn dựa nặng vào các thuật toán cây (tree-based), giới hạn khả năng khám phá các tương tác phi tuyến tính phức tạp và chưa mở rộng sang các kiến trúc học sâu (Deep Learning) để khai thác triệt để tiềm năng của bộ dữ liệu.

Điểm số khi submit tương ứng với từng lần cải tiến	
Version1	0.15033(Kaggle)
Version2	0.12641(Kaggle)
Version3	0.12337(Kaggle)
Version4	0.12725(Kaggle)
Version5	0.12086(Kaggle)
Version6	0.11641(Kaggle)

VI. Hướng cải tiến mô hình

Mặc dù các phiên bản cải tiến liên tiếp đã giúp hệ thống đạt được độ chính xác khá tốt và ổn định, chúng tôi nhận thấy rằng mô hình vẫn còn nhiều cơ hội để được hoàn thiện và nâng cao hơn. Hiện tại, mô hình mới chỉ khai thác được những thông tin nổi bật trong bộ dữ liệu, và chưa hoàn toàn nắm bắt được các khía cạnh ngoại cảnh mang tính lịch sử hoặc kinh tế vĩ mô tại thời điểm giao dịch, khiến khả năng liên kết và giải thích các biến động giá phức tạp của mô hình bị hạn chế. Bên cạnh đó, việc phụ thuộc chủ yếu vào các thuật toán cây cho thấy các phương pháp làm và tinh chỉnh hiện tại vẫn còn có thể được nâng cao thêm (chưa đi sâu vào tinh chỉnh mô hình phù hợp), đặc biệt là trong việc khám phá các tương tác phi tuyến tính sâu hơn và mở ra hướng đi cho việc tích hợp các kiến trúc mạnh mẽ hơn như Học Sâu trong tương lai.

VII. Tham khảo

[1] *A data science framework*
[2] *Machine Learning Mastery With Python Understand Your Data Create Accurate Models and Work Projects End-To-End.pdf*