



Kaggle Challenge House Pricing

Thành viên: Nguyễn Hữu Tri
Lư Hồng Phúc
Lê Thanh Phát
Đỗ Duy Quý

Giảng viên: Đỗ Như Tài

November 11st, 2025

Mục lục

- ◀ 1. Phân tích bài toán và dữ liệu.....●
- ◀ 2. Phương pháp và quá trình thử nghiệm.....●
- ◀ 3. Kết quả và đánh giá.....●
- ◀ 4. Hướng cải tiến mô hình.....●
- ◀ 5. Tài liệu tham khảo.....●

1.1 Phân tích bài toán

- **Bài toán:**

- Khám phá bộ dữ liệu House Prices - Advanced Regression Techniques từ Kaggle
- Triển khai các thuật toán học máy gồm để dự đoán giá bán (SalePrice) của các căn nhà.

1.2 Phân tích dữ liệu

- **Nguồn gốc:** *House Prices – Advanced Regression Techniques (Kaggle)*
<https://www.kaggle.com/c/house-prices-advanced-regression-techniques>.

- **Tổng quan:**

Tập huấn luyện bao gồm **1.460** mẫu với **80** đặc trưng (features)

- cấu trúc,
- vật liệu xây dựng,
- tình trạng sử dụng, và
- các tiện nghi xung quanh.

Gồm: numeric & categorical, biến mục tiêu SalePrice – giá bán thực tế của căn nhà (USD).

1.2 Phân tích dữ liệu


Các cột chính trong dữ liệu

Tên cột	Kiểu dữ liệu	Mô tả
SalePrice	float	Giá bán (biến mục tiêu)
OverallQual	int (1–10)	Chất lượng tổng thể
GrLivArea	int	Diện tích sinh hoạt
GarageCars	int	Số chỗ để xe trong gara
TotalBsmtSF	int	Tổng diện tích tầng hầm

Tên cột	Kiểu dữ liệu	Mô tả
1stFlrSF	int	Diện tích tầng 1
FullBath	int	Số phòng tắm
YearBuilt	int	Năm xây dựng
YearRemodAdd	int	Năm sửa chữa hoặc cải tạo gần
GarageArea	int	Diện tích gara
LotArea	int	Diện tích lô đất
Neighborhood	string	Khu dân cư hoặc vị trí địa lý

1.2 Phân tích dữ liệu

Các cột dữ liệu bị thiếu (train set)



PoolQC, Alley và MiscFeature thiếu gần như hết dữ liệu, hơn **90%**

1.2 Phân tích dữ liệu


Phân tích đơn biến: phân tán và chênh lệch

	count	mean	std	min	25%	50%	75%	max	Skewness	Kurtosis
Id	1460.000000	730.500000	421.610000	1.000000	365.750000	730.500000	1095.250000	1460.000000	0.000000	-1.200000
MSSubClass	1460.000000	56.897000	42.301000	20.000000	20.000000	50.000000	70.000000	190.000000	1.408000	1.580000
LotFrontage	1201.000000	70.050000	24.285000	21.000000	59.000000	69.000000	80.000000	313.000000	2.164000	17.453000
LotArea	1460.000000	10516.828000	9981.265000	1300.000000	7553.500000	9478.500000	11601.500000	215245.000000	12.208000	203.243000
OverallQual	1460.000000	6.099000	1.383000	1.000000	5.000000	6.000000	7.000000	10.000000	0.217000	0.096000
OverallCond	1460.000000	5.575000	1.113000	1.000000	5.000000	5.000000	6.000000	9.000000	0.693000	1.106000
YearBuilt	1460.000000	1971.268000	30.203000	1872.000000	1954.000000	1973.000000	2000.000000	2010.000000	-0.613000	-0.440000
YearRemodAdd	1460.000000	1984.866000	20.645000	1950.000000	1967.000000	1994.000000	2004.000000	2010.000000	-0.504000	-1.272000
MasVnrArea	1452.000000	103.685000	181.066000	0.000000	0.000000	0.000000	160.000000	1600.000000	2.669000	10.082000
BsmtFinSF1	1460.000000	443.640000	456.098000	0.000000	0.000000	383.500000	712.250000	564.000000	0.686000	11.118000
BsmtFinSF2	1460.000000	46.549000	161.319000	0.000000	0.000000	0.000000	0.000000	1474.000000	4.215000	20.113000
BsmtUnfSF	1460.000000	567.240000	441.867000	0.000000	223.000000	477.500000	808.000000	2336.000000	0.920000	0.471000
TotalBsmtSF	1460.000000	1057.429000	438.705000	0.000000	795.750000	991.500000	1298.250000	6110.000000	1.524000	13.250000
1stFlrSF	1460.000000	1162.627000	386.588000	334.000000	882.000000	1087.000000	1391.250000	4692.000000	1.377000	5.746000
2ndFlrSF	1460.000000	346.992000	436.528000	0.000000	0.000000	0.000000	728.000000	2065.000000	0.813000	-0.553000
LowQualFinSF	1460.000000	5.845000	48.623000	0.000000	0.000000	0.000000	0.000000	572.000000	9.011000	83.235000


“LotArea” có mean là **10.516** ft², nhưng max tới **215.245** ft²,

1.2 Phân tích dữ liệu

Phân tích đơn biến: phân tán và chênh lệch



Phân phối “*SalePrice*” **lệch phải** (right-skewed) — phần lớn giá nhà tập trung trong khoảng *100.000 – 250.000 USD*



Outlier ở nhóm nhà cao cấp
Giá nhà cao nhất, lên tới 600.000 USD

1.2 Phân tích dữ liệu


Phân tích đơn biến: tương quan

	Feature	Correlation	AbsCorr
0	OverallQual	0.791000	0.791000
1	GrLivArea	0.708600	0.708600
2	GarageCars	0.640400	0.640400
3	GarageArea	0.623400	0.623400
4	TotalBsmntSF	0.613600	0.613600
5	1stFlrSF	0.605900	0.605900
6	FullBath	0.560700	0.560700
7	TotRmsAbvGrd	0.533700	0.533700
8	YearBuilt	0.522900	0.522900
9	YearRemodAdd	0.507100	0.507100

“OverallQual” và “GrLivArea” có sự tương quan cao nhất đến giá nhà, tương ứng là **0.79** và **0.7**

1.2 Phân tích dữ liệu

Phân tích đơn biến: outlier




Các features
“mạnh”
tương quan
tuyến tính
với giá nhà

Song, các features tồn tại nhiều
outlier, cần được xử lý trước

2.1 Phương pháp triển khai

- Xử lý dữ liệu:
 - làm sạch,
 - xử lý ngoại lệ,
 - bổ sung đặc trưng mới và
 - mã hóa – chuẩn hóa biến
- Phương pháp triển khai:
 - ***Stacking Ensemble***



2.2 Quá trình thử nghiệm

- **Baseline:** giá trị thiếu (NaN) được điền bằng các giá trị đại diện như "Missing" hoặc 0.

Model	MAE	RMSE	RMSLE
LightGBM	16651.286154	28387.948875	0.141144
XGBoost	14943.095703	24586.148946	0.139212
Random Forest	17114.374276	29605.130689	0.153763
CatBoost	16274.396851	26992.278265	0.137384

2.2 Quá trình thử nghiệm

- **Version 2:**

- loại bỏ các điểm outliers (rõ ràng—những ngôi nhà có diện tích ở quá lớn nhưng giá bán lại thấp).
- biến đổi logarit (np.log1p) cho biến mục tiêu (*SalePrice*) để giảm độ lệch.

Model	MAE	RMSE	RMSLE
LightGBM	0.085108	0.130446	0.010363
XGBoost	0.079704	0.120777	0.009576
CatBoost	0.08064	0.117019	0.009285

2.2 Quá trình thử nghiệm

- **Version 3:**

- *xử lý outlier chuyên sâu hơn, rà soát lại và loại bỏ*
- *việc xử lý giá trị bị thiếu: điền hợp lý cho cả biến định tính và định lượng.*

Model	MAE	RMSE	RMSLE
LightGBM	0.078405	0.115593	0.009102
XGBoost	0.074114	0.110397	0.008675
Random Forest	0.08384	0.123675	0.009751
CatBoost	0.076399	0.10998	0.008657

2.2 Quá trình thử nghiệm

- **Version 4:**

- loại bỏ outliers nghiêm ngặt
- điền missing values chi tiết hóa, ví dụ: sử dụng phương pháp điền theo thuộc tính (ví dụ: điền 'None' cho các cột liên quan đến hàm hoặc gara, và điền theo Mode/Median cho các cột khác).

Model	MAE	RMSE	RMSLE
LightGBM	0.080181	0.115668	0.009109
XGBoost	0.07874	0.118302	0.009301
Random Forest	0.083906	0.124437	0.009813
CatBoost	0.077502	0.110046	0.008636

2.2 Quá trình thử nghiệm

- **Version 5:**
 - *chiến lược học tổng hợp (Ensemble Learning).*
 - *kỹ thuật như Averaging Models và Stacking Averaged Models (kết hợp các dự đoán từ Lasso, ElasticNet, LightGBM và CatBoost)*

Model	RMSE
LightGBM	0.07348583
XGBoost	0.08639715
Stacking	0.07950309
CatBoost	0.03260942
Enet	0.10574089

2.2 Quá trình thử nghiệm

- **Version 6:**

- *xử lý missing values: phương pháp thống kê nâng cao (như điền thiếu LotFrontage bằng median của nhóm Neighborhood tương ứng)*
- *loại bỏ các đặc trưng có tỷ lệ giá trị 0 quá cao (áp dụng kỹ thuật Weighted Ensemble kết hợp mô hình Stacking (70%), CatBoost (15%) và ElasticNet (15%))*

Model	RMSE
LightGBM	0.070952045
XGBoost	0.08470602
Stacking	0.0724235
CatBoost	0.03081691
Enet	0.10899926

3. Kết quả và đánh giá

- **Tổng hợp + Kết quả kaggle:**

Điểm số khi submit tương ứng với từng lần cải tiến	
Version1	0.15033(Kaggle)
Version2	0.12641(Kaggle)
Version3	0.12337(Kaggle)
Version4	0.12725(Kaggle)
Version5	0.12086(Kaggle)
Version6	0.11641(Kaggle)

Version 6 đã đạt được chỉ số RMSLE thấp nhất trên tập huấn luyện là 0.07012 cho thấy sự tối ưu hóa tuyệt vời của bộ tham số cuối cùng

---> mô hình chính thức.

4. Hướng cải tiến mô hình

- ***Tồn tại và hướng cải tiến***

Hiện tại, mô hình mới chỉ khai thác được những thông tin nổi bật trong bộ dữ liệu, còn tồn tại:

- *chưa hoàn toàn nắm bắt được các khía cạnh ngoại cảnh mang tính lịch sử hoặc kinh tế vĩ mô tại thời điểm giao dịch,*
- *phụ thuộc chủ yếu vào các thuật toán*
- *chưa đi sâu vào tinh chỉnh mô hình phù hợp, đặc biệt là trong việc khám phá các tương tác phi tuyến tính sâu hơn và mở ra hướng đi cho việc tích hợp các kiến trúc mạnh mẽ hơn như Học Sâu trong tương lai.*



5. Tài liệu tham khảo

- **Tham khảo**

[1] A data science framework

*[2] Machine Learning Mastery With Python Understand Your Data
Create Accurate Models and Work Projects End-To-End.pdf*

The text "THANK YOU FOR LISTENING" is centered on the slide in a large, bold, blue, sans-serif font. To the left and right of the text are decorative elements consisting of four horizontal bars stacked vertically. The bars are colored light blue, green, yellow, and pink from top to bottom.

**THANK YOU
FOR LISTENING**