



House Price Analysis and Prediction Using Machine Learning Algorithms

PHÂN TÍCH VÀ DỰ ĐOÁN GIÁ NHÀ BẰNG CÁC THUẬT TOÁN MACHINE LEARNING

Lê Thanh Phát, Nguyễn Hữu Tri, Lư Hồng Phúc, Đỗ Duy Quý

GIỚI THIỆU

Bối cảnh

Dự đoán giá bất động sản là một ứng dụng phổ biến, nơi giá nhà chịu ảnh hưởng của nhiều yếu tố như vị trí, chất lượng xây dựng, và diện tích. Việc dự đoán chính xác hỗ trợ quyết định đầu tư và quy hoạch đô thị.

Mục tiêu chính:


- Sử dụng bộ dữ liệu "House Prices - Advanced Regression Techniques" từ Kaggle.
- Xây dựng mô hình dự đoán giá bán (SalePrice).
- Thước đo (Metric): Cuộc thi đánh giá dựa trên Lỗi Trung bình Bình phương Căn (RMSE) giữa logarit của giá dự đoán và logarit của giá thực tế.

DỮ LIỆU


"House Prices - Advanced Regression Techniques" từ Kaggle, gồm 1460 mẫu huấn luyện và 1459 mẫu kiểm thử, có hơn 80 đặc trưng mô tả chi tiết

Nguồn dữ liệu: Kaggle

<https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques/data>



PHƯƠNG PHÁP ĐỀ XUẤT



1. Dữ liệu (Input Data)

- 'train.csv' (1460 mẫu), 'test.csv' (1459 mẫu)
- Hơn 80 đặc trưng (cả số và phân loại)

3. Tiền xử lý & Kỹ thuật Đặc trưng

- Biến đổi:** Áp dụng `log1p(SalePrice)`
- Loại bỏ ngoại lệ:** Xóa 2 điểm dữ liệu bất thường
- Xử lý thiếu (Imputation):** Điền 'None'/0, Median theo 'Neighborhood'
- Tạo đặc trưng mới:** 'TotalSF', 'HasBasement'
- Mã hóa (Encoding):** Ordinal & One-Hot

5. Học tập Tổng hợp (Ensemble Learning)

- Thử nghiệm 1: **Stacking** (Lasso + ENet + LGBM + CatBoost)
- Thử nghiệm 2: **Weighted Ensemble** (Stacking + CatBoost + ENet)

2. Phân tích & Khám phá (EDA)

- Phân tích phân phối 'SalePrice' (lệch phải)
- Phân tích giá trị thiếu (Missing Values)
- Phát hiện ngoại lệ (Outliers) ('GrLivArea' > 4000)

4. Xây dựng Mô hình & Đánh giá


- Mô hình cơ sở:** Lasso, Ridge, LightGBM, XGBoost, CatBoost
- Đánh giá (Metric):** Tối ưu theo RMSLE
- Validation:** Sử dụng Cross-Validation (CV)

6. Kết quả (Submission)

- Dự đoán trên tập 'test.csv'
- Nộp file 'submission.csv' lên Kaggle

1. Phân tích & Khám phá dữ liệu (EDA)

a) Phân tích dữ liệu thiếu



2. Quy trình tiền xử lý dữ liệu




4. Đánh giá & Valiadation

Mô tả thước đo và chiến lược để đảm bảo chất lượng mô hình.




3. Kỹ thuật đặc trưng

Tổng quan 5 bước chính trong quy trình lập



5. Mô hình hóa



THỬ NGHIỆM VÀ KẾT QUẢ

Bảng: Quá trình cải tiến mô hình

Thử nghiệm	Cải tiến chính	Score
Version 1	Baseline: XGBoost, xử lý NaN cơ bản.	0,15033
Version 2	Biến đổi log(SalePrice) & Loại bỏ 2 ngoại lệ.	0,12641
Version 3	Tinh chỉnh siêu tham số (Hyperparameter Tuning).	0,12337
Version 4	Kỹ thuật đặc trưng nâng cao (Advanced Features).	0,12725
Version 5	Stacking Ensemble (Lasso, ENet, LGBM, CatBoost).	0,12086
Version 6 (Final)	Weighted Ensemble (70% V5 + 15% CatBoost + 15% ENet).	0,11641



Nhận xét:

Kết luận & Đánh giá

Mặc dù các phiên bản cải tiến liên tiếp đã đạt được độ chính xác khá tốt và ổn định nhưng mô hình vẫn còn nhiều cơ hội để hoàn thiện.

- Hạn chế lớn nhất** là mô hình mới chỉ khai thác được một phần thông tin bên trong dữ liệu và chưa nắm bắt được các yếu tố ngoại sinh.
 - Mô hình thiếu bối cảnh kinh tế vĩ mô và lịch sử thị trường, dẫn đến việc chưa thể giải thích các biến động giá phức tạp.
- Ngoài ra, hệ thống vẫn còn phụ thuộc chủ yếu vào các thuật toán dạng cây (tree-based) và chưa khám phá các kiến trúc học sâu.

HƯỚNG CẢI TIẾN MÔ HÌNH

Hướng 1: Làm giàu Dữ liệu & Bối cảnh

Tích hợp thêm dữ liệu về bối cảnh kinh tế vĩ mô và lịch sử thị trường tại thời điểm giao dịch (ví dụ: lãi suất, quy hoạch đô thị) để mô hình có khả năng liên kết và giải thích các biến động giá tốt hơn.

Hướng 2: Khai thác Kiến trúc Mô hình Nâng cao

Mở rộng sang các kiến trúc học sâu (Deep Learning) để khai thác triệt để các tương tác phi tuyến tính phức tạp, thay vì chỉ dựa vào các thuật toán cây đã đạt đến giới hạn.

Hướng 3: Tinh chỉnh Xử lý & Đánh giá

Tiếp tục đi sâu vào tinh chỉnh các phương pháp xử lý dữ liệu (như điền giá trị thiếu thông minh hơn) và tinh chỉnh sâu hơn vào các tham số của mô hình để phù hợp nhất với bộ dữ liệu.