Phân tích và dự đoán các thể loại âm nhạc bằng các thuật toán Machine Learning

Thành viên: *Lê Thanh Phát, Nguyễn Hữu Tri, Lư Hồng Phúc, Đỗ Duy Quý*

Abstract - Phân loại thể loại nhạc là một bài toán quan trọng trong kỷ nguyên số, giúp tối ưu hóa trải nghiệm người dùng trên các nền tảng phát trực tuyến. Trong nghiên cứu này, chúng tôi giải quyết bài toán "Music Genre Classification" trên Kaggle bằng cách phân tích các đặc trưng âm học (như danceability, energy, tempo) để dự đoán thể loại nhạc. Chúng tôi đã triển khai một quy trình thực nghiệm toàn diện, bắt đầu từ mô hình cơ sở Random Forest, sau đó phát triển qua các thuật toán Gradient Boosting mạnh mẽ (XGBoost, LightGBM, CatBoost) và các kỹ thuật Ensemble Learning. Kết quả thực nghiệm cho thấy các mô hình Gradient Boosting hoạt động hiệu quả vượt trội trên dữ liệu dạng bảng so với các thuật toán cổ điển như SVM hay KNN. Đặc biệt, chúng tôi phát hiện rằng cân bằng dữ liệu output bằng (oversampling) làm giảm khả năng tổng quát hóa, trong khi chiến lược Stacking gọn nhẹ trên các mô hình tốt nhất (A-team) lại mang lại hiệu suất cao nhất. Hệ thống cuối cùng đạt chỉ số F1-macro là 0.56944 trên bảng xếp hạng Kaggle, cải thiện 10.6% so với mức cơ sở ban đầu.

I. Giới thiệu

Sự bùng nổ của các dịch vụ phát nhạc trực tuyến (như Spotify, Apple Music) đã tạo ra kho dữ liệu âm nhạc khổng lồ, đặt ra thách thức lớn trong việc tổ chức, tìm kiếm và gợi ý nội dung. Việc gán nhãn thủ công cho hàng triệu bài hát là bất khả thi, do đó, các hệ thống phân loại thể loại nhạc tự động (Automatic Music Genre Classification) trở thành một nhu cầu cấp thiết. Một hệ thống phân loại chính xác không chỉ hỗ trợ việc quản lý thư viện nhạc mà còn là nền tảng cho các thuật toán gợi ý (recommendation systems) cá nhân hóa.

Bài báo này tập trung vào giải quyết bài toán phân loại đa lớp (multi-class classification) trên bộ dữ liệu "Music Genre Classification" từ Kaggle. Mục tiêu là xây dựng mô hình học máy để dự đoán chính xác nhãn thể loại nhạc (Class) dựa trên các đặc trưng đầu vào như đặc trưng âm học: danceability, energy, acousticness, valence, instrumentalness...; đặc trưng vật lý: loudness, tempo, duration, key, mode. Thách thức chính của bài toán nằm ở sự phức tạp của dữ liệu âm thanh, sự chồng lấn giữa các thể loại nhạc gần nhau, và vấn đề mất cân bằng dữ liệu (class imbalance) giữa các lớp.

Khác với các phương pháp tiếp cận truyền thống chỉ dựa trên một mô hình đơn lẻ, nghiên cứu này đề xuất một quy trình cải tiến lặp lại (iterative improvement) qua 6 phiên bản (từ V1 đến V6). Chúng tôi bắt đầu với mô hình cơ sở Random Forest để thiết lập mốc so sánh (baseline). Sau đó, chúng tôi khai thác sức mạnh của các thuật toán Gradient Boosting hiện đại gồm XGBoost, LightGBM và CatBoost để xử lý các mối quan hệ phi tuyến phức tạp trong dữ liệu. Chúng tôi cũng tiến hành phân tích sâu về sự đánh đổi giữa việc đa dạng hóa mô hình (thêm SVM, KNN) và chất lượng mô hình, cũng như tác động tiêu cực của việc cân bằng dữ liệu (oversampling). Kết quả cuối cùng, mô hình Stacking kết hợp ba thuật toán Boosting mạnh nhất đã giúp nâng chỉ số F1-macro từ 0.514 (baseline) lên 0.569 (phiên bản tốt nhất), chứng minh tính hiệu quả của phương pháp đề xuất

Phần còn lại của bài báo được cấu trúc như sau. Phần II: phân tích bài toán và dữ liệu. Phần III: Phương pháp và quá trình thử nghiệm. Phần IV: Kết quả và đánh giá. Phần V: Hướng cải tiến mô hình. Phần VI: Tài liệu tham khảo.

II. Phân tích bài toán

1. Phân tích bối cảnh và mục tiêu

Khối lượng các bản nhạc được phát hành mỗi ngày là tăng, các thể loại âm nhạc mới cũng được sáng tạo đa dạng theo phong cách của nghệ sĩ. Do đó việc cập nhật thủ công và gán nhãn thủ công còn quá chậm so với việc phát triển nhanh chóng của âm nhạc. Từ đó, bài toán đặt ra là xây dựng một hệ thống có khả năng tự động gán nhãn thể loại nhạc dựa trên các đặc trưng kỹ thuật số của âm thanh. Đây là bài toán cốt lõi giúp các nền tảng streaming cải thiện hệ thống gợi ý (recommendation system) và quản lý kho dữ liệu.

Dựa trên yêu cầu của cuộc thi Kaggle "Music Genre Classification", bài toán được xác định cụ thể: loại bài toán là bài toán phân loại đa lớp (Multi-class Classification) trong học máy có giám sát. Đầu vào (Input): Dữ liệu dạng bảng (tabular data) chứa các đặc trưng âm học và vật lý của bản nhạc.

Các đặc trưng này bao gồm: đặc trưng tính chất: danceability (độ phù hợp để nhảy), energy (năng lượng), valence (sắc thái cảm xúc), liveness (độ sống động), acousticness (tính mộc), instrumentalness (tính nhạc cụ), speechiness (tính lời thoại); đặc trưng vật lý: loudness (độ to), tempo (nhịp độ), duration (thời lượng), time_signature (nhịp), mode và key (tông/điệu). Đầu ra (Output): Biến mục tiêu Class - đại diện cho thể loại của bản nhạc (ví dụ: Rock, Pop, Jazz, v.v).

Mục tiêu huấn luyện: tìm hàm ánh xạ $f(X) \rightarrow y$ sao cho mô hình dự đoán chính xác thể loại nhạc trên tập dữ liệu kiểm thử.

Trong quá trình tiếp cận bài toán, chúng tôi xác định các thách thức kỹ thuật sau dựa trên đặc điểm dữ liệu: dữ liệu mất cân bằng (Imbalanced Data): phân bố số lượng bài hát giữa các thể loại không đồng đều. Điều này khiến các mô hình thông thường có xu hướng thiên vị các lớp đa số (major classes) và dự đoán kém ở các lớp thiểu số (minor classes). Tính chồng lấn giữa các lớp: ranh giới giữa các thể loại nhạc thường không rõ ràng (ví dụ: ranh giới giữa Rock và Alternative). Các mối quan hệ giữa đặc trưng đầu vào và nhãn mục tiêu là phi tuyến tính và phức tạp, khiến các mô hình đơn giản như KNN hay SVM khó đạt hiệu suất cao. Và nhiễu dữ liệu: một số đặc trưng như tempo, duration, loudness chứa các giá trị bất thường (outliers) cần được xử lý để tránh ảnh hưởng đến quá trình hội tụ của mô hình.

Do đặc thù dữ liệu mất cân bằng, độ chính xác đơn thuần (Accuracy) không phản ánh trung thực hiệu suất của mô hình (ví dụ: mô hình có thể đạt accuracy cao chỉ bằng cách dự đoán toàn bộ là lớp đa số). Vì vậy, chúng tôi sử dụng chỉ số chính (Primary Metric): F1-macro. Đây là chỉ số quan trọng nhất được sử dụng để xếp hạng trên Kaggle và đánh giá nội bộ. F1-macro tính toán trung bình cộng của điểm F1 trên từng lớp, không phụ thuộc vào số lượng mẫu của lớp đó. Điều này đảm bảo mô hình phải hoạt động tốt trên cả các thể loại nhạc hiếm gặp. Chỉ số tham khảo khác: accuracy, để có cái nhìn tổng quan về tỷ lệ đoán đúng; precision-macro & recall-macro: để phân tích chi tiết xem mô hình đang gặp vấn đề ở việc nhận diện sai (thấp Precision) hay bỏ sót (thấp Recall) ở các lớp cụ thể.

2. Data Description (Mô tả dữ liệu)

Bộ dữ liệu được sử dụng là Music Genre Classification (Kaggle). Tập huấn luyện (train.csv) và tập kiểm thử (test.csv) có thể truy cập tại: https://www.kaggle.com/competitions/shai-music-genre-classification/data

Tập huấn luyện (train.csv) bao gồm 14396 mẫu, trong khi tập kiểm thử (test.csv) gồm 3600 mẫu. Mỗi dòng dữ liệu đại diện cho một bài hát, với hơn 16 đặc trưng (features) mô tả chi tiết về bài hát đó: nhịp điệu, tông, năng lượng, sự sống động,...

Trong tập dữ liệu có nhiều điểm dữ liệu đặc biệt. Dữ liệu nhiễu và outliers: các biến số thực như tempo, duration, loudness chứa các giá trị bất thường (outliers) cần được xử lý trước khi đưa vào mô hình. Mất cân bằng lớp: phân phối giữa các thể loại nhạc (Class) không đồng đều, dẫn đến việc một số lớp có độ chính xác rất cao trong khi các lớp khác rất thấp. Đặc trưng hỗn hợp: dữ liệu bao gồm cả các biến định lượng liên tục (như loudness, tempo) và các biến phân loại/rời rạc (như key, mode), đòi hỏi các phương pháp chuẩn hóa phù hợp cho từng loại dữ liệu khác nhau.

Bảng sau đây sẽ mô tả chi tiết các đặc trưng quan trọng trong tập dữ liệu. Ngoài bảng này ra, còn có các đặc trưng khác như liveness, speechiness và các thông tin định danh như Artist Name, Track Name (thường được loại bỏ trong quá trình huấn luyện để tập trung vào đặc trưng âm thanh. Song, chúng ta có thể sử dụng Artist Name như một mốc tham chiếu và bổ sung vào quyết định bởi vì hầu hết các tác giả chỉ sáng tác một số thể loại nhất định nào đó, hoặc chỉ sáng tác một thể loại mà thôi)

Tên cột	Kiểu dữ liệu	Mô tả
Class	int (Categorical)	Thể loại nhạc (Biến mục tiêu - Target)
Danceability	float	Độ phù hợp để khiêu vũ/nhảy của bản nhạc
Energy	float	Mức độ năng lượng và cường độ của bản nhạc
Loudness	float	Độ lớn âm thanh trung bình (dB)
Tempo	float	Nhịp độ của bản nhạc (Beats per minute)
Valence	float	Sắc thái cảm xúc (tích cực/tiêu cực)
Acousticness	float	Độ mộc của âm thanh (không qua điện tử)
Instrumentalness	float	Tỷ lệ âm thanh nhạc cụ so với giọng hát
Duration	float	Thời lượng của bản nhạc (ms)
Key/Mode	int	Tông và điệu thức của bản nhạc

Fig1. Bảng mô tả các đặc trưng tiêu biểu

3. Phân Tích Dữ Liệu

Kết quả thống kê cho thấy một số cột trong cả tập huấn luyện (train) và tập kiểm thử (test) chứa giá trị bị thiếu, với mức độ khác nhau giữa các đặc trưng. Cụ thể, trong tập huấn luyện, các đặc trưng như instrumentalness, key và popularity đều có giá trị bị thiếu và cần được xử lý trước khi đưa vào mô hình. Trong đó đặc trung thiếu nhiều nhất là instrumentalness - gần 25%

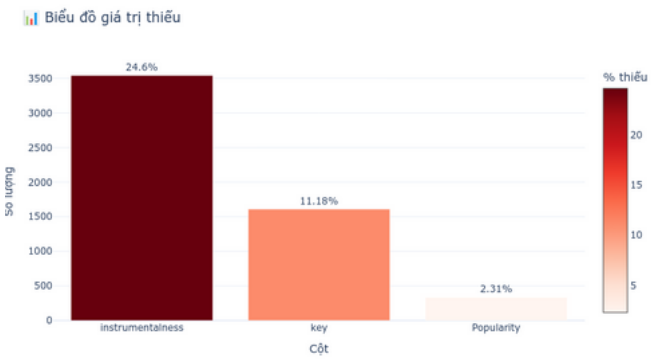

Fig2. Biểu đồ cột mô tả các giá trị thiếu tập train

Cụ thể, “instrumentalness”, đây là đặc trưng có tỷ lệ thiếu dữ liệu nghiêm trọng nhất, chiếm gần 25% tổng số mẫu quan sát. Việc thiếu hụt này có thể ảnh hưởng lớn đến khả năng phân loại các dòng nhạc không lời; “key” và “popularity”, hai biến này cũng ghi nhận lượng đáng kể các giá trị null. Chiến lược đề xuất: Dựa trên mức độ thiếu hụt, chúng tôi cân nhắc loại bỏ cột instrumentalness nếu nó gây nhiễu quá lớn, hoặc điền các giá trị thiếu dựa trên trung vị (median) cho các biến còn lại để duy trì kích thước mẫu.

Biểu đồ phân phối tần suất của biến mục tiêu (Class) cho thấy dữ liệu bị lệch (skewed distribution) đáng kể. Class 10 là lớp chiếm ưu thế áp đảo (dominant class) với số lượng khoảng 4.000 mẫu. Các lớp còn lại có số lượng mẫu thấp hơn nhiều. Nhận xét: Sự mất cân bằng này là nguyên nhân chính khiến các mô hình cơ sở (baseline) thường có xu hướng dự đoán thiên lệch về Class 10. Do đó chúng tôi cân nhắc sử dụng các chỉ số đánh giá phù hợp như F1-Macro thay vì Accuracy

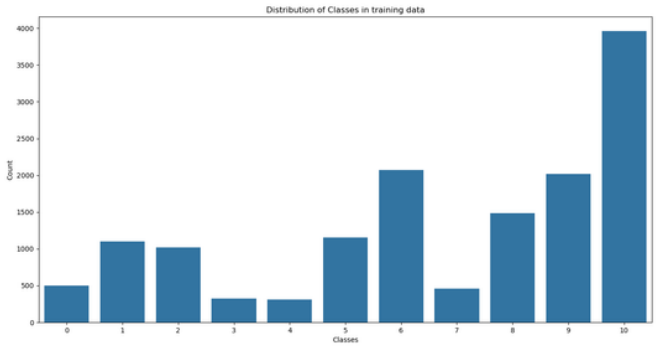

Fig3. Biểu đồ cột mô tả phân phối của biến mục tiêu

Thông qua biểu đồ Box-plot trên các biến số thực, chúng tôi ghi nhận được các đặc trưng như loudness, instrumentalness, duration (thời lượng), liveness và speechiness có miền giá trị biến thiên rất rộng và xuất hiện dày đặc các giá trị ngoại lai (outliers) nằm xa khoảng tứ phân vị. Do vậy dữ liệu cần được chuẩn hóa (Scaling) mạnh mẽ (ví dụ: RobustScaler hoặc Standard Scaler) để giảm thiểu tác động tiêu cực lên các thuật toán nhạy cảm với khoảng cách.

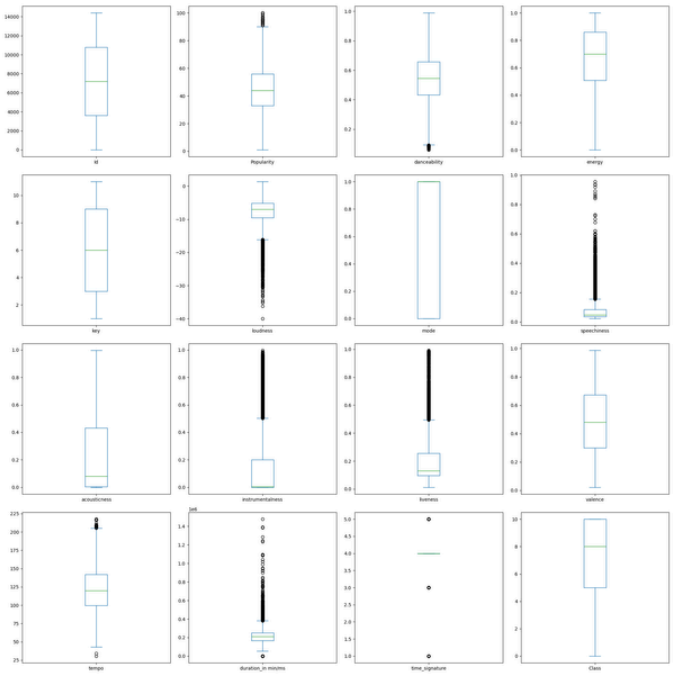

Fig4. Biểu đồ mô tả sự phân bố giá trị của các đặc trưng

Ma trận tương quan chỉ ra mối liên hệ giữa các đặc trưng và thể loại. Tương quan dương: “energy” và “duration” cho thấy mối tương quan thuận chiều đáng kể với biến mục tiêu. Tương quan âm: “acousticness” có mối tương quan nghịch biến cao nhất, cho thấy đây là một tín hiệu quan trọng để phân biệt các dòng nhạc (ví dụ: phân biệt nhạc điện tử và nhạc mộc)

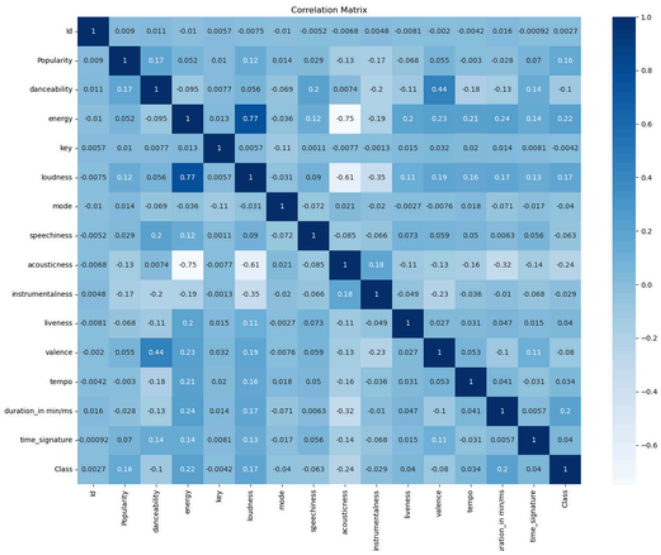

Fig5. Biểu đồ mô tả sự tương quan giữa các đặc trưng

Phân tích sâu hơn về sự phân tách lớp thông qua biểu đồ cặp ta thấy: đặc trưng phân loại tốt như “acousticness”, “energy” và “loudness” cho thấy khả năng tách biệt các nhóm dữ liệu khá tốt (khoảng cách giữa các đường trung vị của các lớp lớn, vùng chồng lấn IQR nhỏ).

Đặc biệt, Class 7 thể hiện các đặc tính phân phối (về energy, loudness, valence) khác biệt hoàn toàn so với các lớp còn lại, dự báo mô hình sẽ dễ dàng nhận diện lớp này với độ chính xác cao. Đặc trưng phân loại kém: “popularity” cho thấy mức độ chồng lấn dữ liệu rất lớn giữa các lớp. Có thể hiểu rằng độ nổi tiếng của bài hát không có quy luật rõ ràng theo thể loại nhạc và có thể gây nhiễu cho mô hình. Và “danceability” có mức độ chồng lấn trung bình.

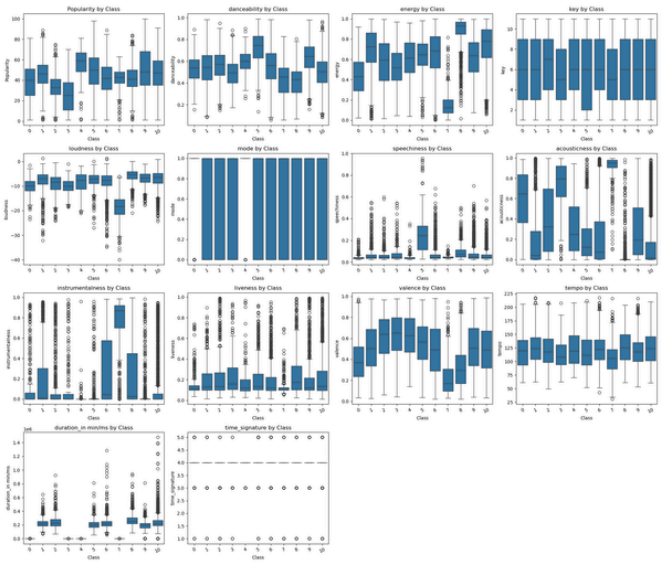

Fig6. Biểu đồ boxplot mô tả sự chồng lấn giữa các lớp

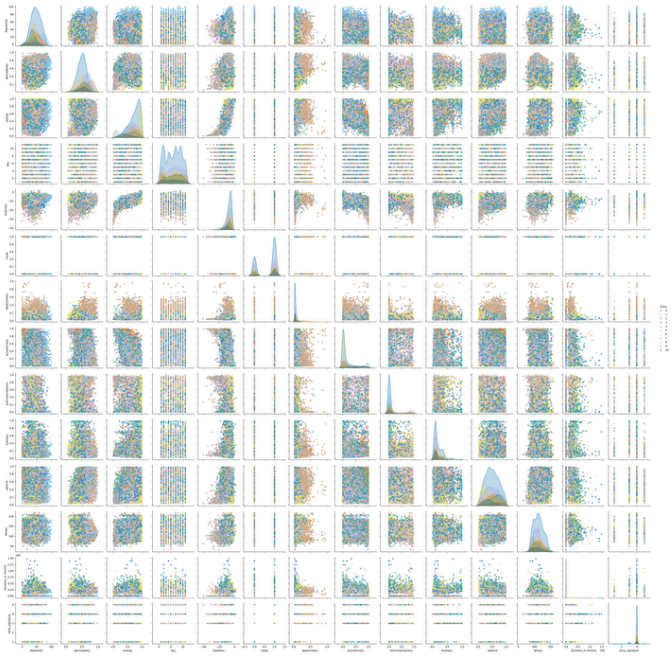

Fig7. Biểu đồ pairplot mô tả sự chồng lấn giữa các lớp

Kết quả thực nghiệm giảm chiều dữ liệu (Dimensionality Reduction) sử dụng các kỹ thuật t-SNE và UMAP cho thấy: các cụm dữ liệu (clusters) có được hình thành nhưng ranh giới không rõ ràng và có sự giao thoa (overlap) đáng kể giữa các lớp. Kết luận: Mối quan hệ giữa các đặc trưng âm thanh đầu vào và thể loại nhạc là phi tuyến tính (non-linear) và phức tạp. Do đó, các mô hình tuyến tính đơn giản sẽ khó đạt hiệu suất cao, thay vào đó cần ưu tiên các mô hình cây quyết định (Decision Trees) hoặc mạng nơ-ron để xử lý các biên quyết định phức tạp này.

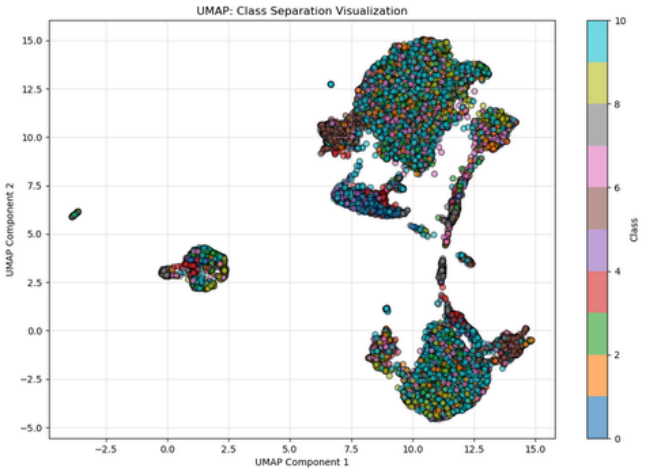

Fig8. Biểu đồ giảm chiều dữ liệu sử dụng UMAP

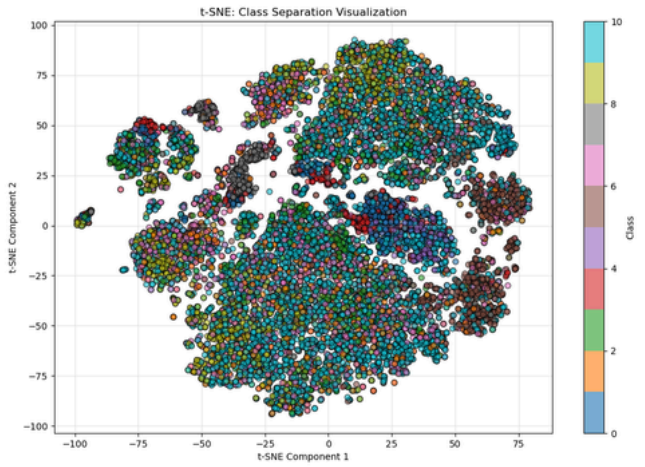

Fig9. Biểu đồ giảm chiều dữ liệu sử dụng t-SNE

Khác với bài toán dự đoán giá nhà có mối quan hệ tuyến tính rõ ràng (ví dụ: diện tích càng lớn giá càng cao), dữ liệu âm nhạc thể hiện các mối quan hệ phức tạp hơn.

Tính phi tuyến (Non-linearity): Sự thất bại của các mô hình tuyến tính hoặc dựa trên khoảng cách như KNN và SVM (hiệu suất thấp hơn hẳn so với Boosting) cho thấy tương quan giữa các đặc trưng âm học và thể loại nhạc là phi tuyến tính.

Sự chồng lấn (Overlapping): Các thể loại nhạc có sự giao thoa lớn về đặc trưng (ví dụ: Energy cao có thể xuất hiện ở cả Rock và EDM). Điều này đòi hỏi các mô hình có khả năng tạo ra các đường ranh giới quyết định (decision boundaries) phức tạp như XGBoost hay LightGBM.

Feature Importance: Các đặc trưng âm học (acoustic features) đóng vai trò quan trọng hơn các đặc trưng về độ phổ biến hay thông tin văn bản trong việc phân loại chính xác thể loại

III. Phương pháp và quá trình thử nghiệm

A. Phương pháp

Trong đề tài Music Genre Classification, chúng tôi xem bài toán dưới dạng phân loại đa lớp, trong đó mỗi bản nhạc được biểu diễn bằng các đặc trưng âm học trích xuất sẵn và nhãn mục tiêu Class là thể loại nhạc.

Các đặc trưng bao gồm những đại lượng liên quan đến tính chất bản nhạc như danceability, energy, valence, liveness, acousticness, instrumentalness, speechiness, cùng với các đặc trưng vật lý như loudness, tempo, thời lượng (duration) và nhịp/phách (time_signature, mode, key). Một số đặc trưng về độ phổ biến cũng được giữ lại nhưng không phải trọng tâm, vì chúng tôi ưu tiên các đặc trưng âm học có ý nghĩa trực tiếp hơn đối với mô hình.

Do số lượng lớp tương đối lớn và phân bố không cân bằng, độ chính xác (Accuracy) không phản ánh đầy đủ chất lượng mô hình. Vì vậy, chỉ số chính được sử dụng trong toàn bộ quá trình là F1_macro, giúp đánh giá cân bằng hơn giữa các lớp, kể cả lớp ít mẫu. Bên cạnh đó, chúng tôi vẫn theo dõi thêm Accuracy, Precision_macro và Recall_macro để hỗ trợ phân tích chi tiết ở từng thí nghiệm.

Quy trình tiền xử lý được triển khai dưới dạng các pipeline trong thư mục src/preprocess và src/pipeline. Dữ liệu được kiểm tra và xử lý những giá trị bất thường ở các biến như tempo, duration, loudness.

Các cột định danh thuần văn bản (tên bài hát, tên nghệ sĩ) được loại bỏ hoặc chỉ sử dụng gián tiếp, nhằm tập trung vào các đặc trưng số liên quan trực tiếp đến nội dung âm nhạc. Các đặc trưng số được chuẩn hóa ở mức vừa phải để hỗ trợ các mô hình nhạy với thang đo (như SVM, KNN), đồng thời vẫn phù hợp với các mô hình cây như RandomForest, LightGBM, XGBoost, CatBoost.

Để ước lượng khả năng tổng quát hóa, chúng tôi sử dụng Stratified K-Fold Cross-Validation (thường là 5 fold), đảm bảo phân bố nhãn trong từng fold gần giống phân bố chung. Với mỗi mô hình, chúng tôi ghi nhận F1_macro trung bình trên các fold, độ lệch chuẩn và F1_macro trên tập OOF (out-of-fold).

Song song đó, Kaggle Public Leaderboard được coi như "tập kiểm thử ẩn", giúp kiểm tra xem mô hình có đang quá khớp vào train/OOF hoặc nhạy cảm với sai lệch phân phối giữa train và test hay không.

Trên nền tảng đó, chúng tôi xây dựng một chuỗi mô hình tăng dần độ phức tạp. Bắt đầu từ mô hình đơn giản (RandomForest), sau đó lần lượt bổ sung các mô hình boosting, thử các chiến lược voting, stacking, tuning siêu tham số và cân bằng dữ liệu. Mỗi thay đổi đều được đánh giá bằng các con số cụ thể (F1_macro trên CV, OOF và Kaggle) để làm cơ sở quyết định cho bước tiếp theo.

B. Quá trình thử nghiệm

Quá trình thử nghiệm được tổ chức thành sáu phiên bản từ V1 đến V6. Mỗi phiên bản ứng với một hướng tiếp cận khác nhau: từ baseline đơn giản, sang mô hình boosting, rồi ensemble và stacking, sau đó là thử cân bằng dữ liệu, và cuối cùng là cấu hình "chốt" gọn hơn nhưng hiệu quả hơn. Các con số trên CV, OOF và Kaggle giúp chúng tôi đánh giá khách quan từng bước.

1) Phiên bản V1 – Baseline RandomForest

Ở phiên bản V1, chúng tôi xây dựng một pipeline cơ bản: dữ liệu sau tiền xử lý được đưa trực tiếp vào mô hình RandomForest. Trên fold cuối của cross-validation, báo cáo chi tiết cho thấy Accuracy ≈ 0,51, F1_macro ≈ 0,5634, Precision_macro ≈ 0,5796 và Recall_macro ≈ 0,5604. Điều này cho thấy mô hình đã khai thác được một phần thông tin từ các đặc trưng âm học, nhưng vẫn có những hạn chế nhất định.

Quan sát theo từng lớp, các lớp như 3 và 7 đạt F1 khá cao (lớp 3 khoảng 0,83, lớp 7 khoảng 0,96), trong khi một số lớp khó như lớp 1 có F1 rất thấp (≈ 0,02). Như vậy, ngay ở baseline đã có thể thấy vấn đề quen thuộc trong bài toán không cân bằng lớp: mô hình xử lý khá tốt các lớp "dễ", nhưng những lớp ít mẫu hoặc khó phân biệt thì bị bỏ sót.

Khi nộp mô hình RandomForest baseline này lên Kaggle, điểm F1_macro trên leaderboard là 0.51468, thấp hơn khoảng 0,05 so với F1_macro trên fold cuối. Điều này cho thấy RandomForest ở cấu hình đơn giản chưa đủ để khai thác tốt cấu trúc dữ liệu, và V1 chủ yếu được dùng như mốc ban đầu để so sánh.

Model	Accuracy	Precision macro	Recall macro	F1 macro	Kaggle F1 macro
Random Forest Fold4	0.51	0.5795	0.5604	0.5634	–
Random Forest (submit)	–	–	–	–	0.5146

Bảng V1. Kết quả phiên bản V1

2) Phiên bản V2 – Thêm các mô hình boosting

Từ kết quả V1, chúng tôi kỳ vọng các mô hình boosting sẽ khai thác tốt hơn cấu trúc đặc trưng, nên ở V2 chúng tôi huấn luyện bốn mô hình: RandomForest, LightGBM, XGBoost và CatBoost, trên cùng một pipeline tiền xử lý. Kết quả cross-validation được tóm tắt trong bảng sau.

Model	Mean CV F1	Std CV F1	OOF F1
XGBoost	0.580747	0.00583	0.580819
LightGBM	0.580455	0.003037	0.580571
CatBoost	0.571812	0.007168	0.571978
RandomForest	0.556624	0.005795	0.556995

Bảng V2.1. Hiệu suất các mô hình cơ sở ở giai đoạn V2

Ba mô hình boosting đều vượt RandomForest: XGBoost và LightGBM cùng đạt khoảng 0,581 F1_macro, CatBoost đạt khoảng 0,572, trong khi RandomForest chỉ khoảng 0,557. Độ lệch chuẩn nhỏ (đặc biệt với LightGBM) cho thấy các mô hình boosting khá ổn định giữa các fold.

Dựa trên các kết quả này, chúng tôi xây dựng một ensemble đơn giản dựa trên các mô hình boosting. Khi nộp lên Kaggle, điểm F1_macro tăng từ 0.51468 (V1) lên 0.55079 (V2).

Chiến lược	F1_macro (CV/OOF, xấp xỉ)	Kaggle F1_macro
Best single (XGBoost)	≈ 0.581	–
Best single (LightGBM)	≈ 0.581	–
Boosting Ensemble (V2)	≈ 0.58	0.55079

Bảng V2.2. Kết quả phiên bản V2 – Ensemble boosting chính

Như vậy, V2 cho thấy việc chuyển từ một mô hình cây thuần túy sang các mô hình boosting và ensemble đơn giản đã giúp cải thiện rõ rệt điểm số trên leaderboard, đồng thời khoảng cách giữa CV và Kaggle cũng thu hẹp lại.

3) Phiên bản V3 – Mở rộng mô hình và stacking meta

Model	F1 macro	Accuracy	Precision macro	Recall macro
CatBoost	0.575677	0.549944	0.607976	0.579318
LightGBM	0.575371	0.542025	0.593165	0.573695
XGBoost	0.571738	0.523688	0.581239	0.570517
Random Forest	0.559542	0.525841	0.589477	0.558327
SVM	0.545173	0.517575	0.575545	0.545282
KNN	0.51726	0.482008	0.530837	0.522345
Naive Bayes	0.426159	0.371562	0.425248	0.515441

Bảng V3.1. Hiệu suất F1_macro của các mô hình base và ensemble ở V4

Ở V3, chúng tôi thử tăng thêm mức độ đa dạng của mô hình. Ngoài bốn mô hình ở V2, chúng tôi bổ sung thêm SVM, KNN và Naive Bayes. Các mô hình này được huấn luyện trên cùng pipeline, sau đó đánh giá bằng F1_macro, Accuracy, Precision_macro và Recall_macro.

Trong số các mô hình base, CatBoost và LightGBM đang dẫn đầu với F1_macro khoảng 0,575, XGBoost đạt khoảng 0,572, RandomForest khoảng 0,56, còn SVM, KNN và NaiveBayes thấp hơn rõ rệt.

Dựa trên các mô hình có F1_macro tương đối tốt, chúng tôi xây dựng một ensemble đơn giản gồm CatBoost, LightGBM, XGBoost, RandomForest, SVM với trọng số bằng nhau (0,2 mỗi mô hình). Ensemble này đạt F1_macro ≈ 0.5800.

Thành phần ensemble	Trọng số	F1_macro (CV/OOF)
CatBoost	0.2	–
LightGBM	0.2	–
XGBoost	0.2	–
RandomForest	0.2	–
SVM	0.2	–
Ensemble V3	–	**0.58**

Bảng V3.2. Ensemble V3 với trọng số đều trên 5 mô hình top

Điểm khác biệt của V3 nằm ở tầng meta: chúng tôi ghép các dự đoán OOF của nhiều mô hình lại thành 14 396 mẫu meta với 55 đặc trưng, và huấn luyện một mô hình stacking trên không gian này. Mô hình stacking đạt F1_macro OOF ≈ 0.6099.

Chiến lược	Meta Train Shape	F1_macro (OOF)	Kaggle F1_macro
Stacking (V3)	(14396, 55)	0.6099	0.55555

Bảng V3.3. Hiệu suất stacking ở V3

Khi nộp lên Kaggle, V3 đạt 0.55555, nhỉnh hơn V2 khoảng 0,005. Tuy nhiên, chênh lệch giữa OOF (~0,6099) và leaderboard (~0,5556) khá lớn, cho thấy mô hình meta đã học rất tốt trên OOF nhưng không chuyển hóa hoàn toàn được lợi thế đó sang tập test. Dù vậy, V3 vẫn là phiên bản tốt nhất tại thời điểm đó và là cơ sở để so sánh các phiên bản sau.

4) Phiên bản V4 – Tuning tham số & ensemble 7 mô hình

Ở V4, chúng tôi tập trung tuning kỹ hơn các mô hình boosting (XGBoost, LightGBM, CatBoost), đồng thời thử nghiệm một ensemble gồm cả 7 mô hình (thêm SVM, KNN, NaiveBayes). Kết quả từng mô hình được tóm tắt trong Bảng V4.1.

Model	F1_macro	Accuracy	Precision macro	Recall macro
XGBoost	0.581825	0.538275	0.593932	0.580733
LightGBM	0.577859	0.548486	0.593574	0.58322
CatBoost	0.573215	0.54793	0.599502	0.57584
Random Forest	0.562297	0.530286	0.592832	0.560738
SVM	0.547974	0.517297	0.569542	0.54825
KNN	0.518309	0.472214	0.523506	0.52335
Naive Bayes	0.426159	0.371562	0.425248	0.515441

Bảng V4.1. Hiệu suất F1_macro của các mô hình base và ensemble ở V4

So với V3, các mô hình boosting đã cải thiện nhẹ: XGBoost lên khoảng 0,5818, LightGBM khoảng 0,5779, CatBoost khoảng 0,5732. Tuy nhiên, các mô hình yếu như KNN và NaiveBayes vẫn ở mức F1_macro thấp.

Khi tối ưu trọng số cho ensemble 7 mô hình, nghiệm thu được là trọng số gần bằng nhau cho tất cả (khoảng 0,1429 mỗi mô hình), và ensemble đạt F1_macro CV ≈ 0.5741.

Bảng V4.2. Ensemble 7 mô hình ở V4

Mô hình	Trọng số tối ưu
LightGBM	0.1429
XGBoost	0.1429
CatBoost	0.1429
Random Forest	0.1429
SVM	0.1429
KNN	0.1429
NaiveBayes	0.1429
Ensemble V4 (CV F1_macro)	0.5741

Khi nộp lên Kaggle, V4 đạt 0.54642, thấp hơn V3. Như vậy, mặc dù tuning giúp từng mô hình boosting mạnh hơn, việc kết hợp thêm nhiều mô hình yếu với trọng số gần như bằng nhau lại làm giảm chất lượng ensemble. V4 cho thấy không phải lúc nào thêm nhiều mô hình hơn cũng tốt nếu chất lượng các mô hình đó không đồng đều

5) Phiên bản V5 – Cân bằng dữ liệu và hiệu năng giảm mạnh

Ở V5, chúng tôi chuyển sang hướng data-centric, thử áp dụng các kỹ thuật như class_weight và oversampling để xử lý mất cân bằng lớp, với kỳ vọng cải thiện recall cho các lớp ít mẫu. Kết quả F1_macro trung bình qua CV của các mô hình boosting được trình bày trong Bảng V5.1.

Model	CV_F1
LightGBM	0.56953
XGBoost	0.569737
CatBoost	0.569048
RandomForest	0.547661

Bảng V3.3. Hiệu suất stacking ở V3

Các con số trên CV vẫn ở mức chấp nhận được, khoảng 0,57 cho các mô hình boosting. Dựa trên đó, chúng tôi xây dựng một ensemble 4 mô hình (LightGBM, XGBoost, CatBoost, RandomForest) với trọng số đều 0,25, đạt F1_macro CV ≈ 0.57869.

Mô hình	Trọng số
LightGBM	0.25
XGBoost	0.25
CatBoost	0.25
RandomForest	0.25
Ensemble V5 (CV F1_macro)	**0.57869**

Bảng V3.3. Hiệu suất stacking ở V5

Tuy nhiên, khi nộp lên Kaggle, V5 chỉ đạt 0.50793, thấp nhất trong toàn bộ các version. Khoảng cách rất lớn giữa CV (~0,579) và leaderboard (~0,508) cho thấy mô hình đang học theo phân phối đã được can thiệp (balanced) trên train, trong khi tập test vẫn giữ phân phối gốc. Điều này làm giảm khả năng tổng quát hóa, và V5 trở thành một ví dụ cho việc cân bằng dữ liệu không đúng cách có thể làm hại hiệu năng hơn là cải thiện.

6) Phiên bản V6 – "A-team" boosting và stacking gọn

V6 được thiết kế dựa trên kinh nghiệm rút ra từ các version trước: tập trung vào những mô hình mạnh nhất, tránh ensemble quá "loãng" và không can thiệp cực đoan vào phân phối dữ liệu. Ở phiên bản này, chúng tôi quay lại sử dụng dữ liệu gốc (không oversampling, không class_weight mạnh), chỉ giữ ba mô hình boosting chính là XGBoost, LightGBM và CatBoost, và xem xét thêm RandomForest như một lựa chọn phụ.

Chúng tôi thực hiện grid search trọng số cho voting Top 3 (XGB, LGBM, Cat). Bộ trọng số tốt nhất là: XGBoost: 0.25; LightGBM: 0.40; CatBoost: 0.35 với F1_macro OOF ≈ 0.58899. Khi mở rộng sang All 4 (thêm RandomForest), kết quả tối ưu vẫn giữ nguyên trọng số cho XGBoost, LightGBM, CatBoost, trong khi trọng số của RandomForest là 0.0. Như vậy, RandomForest không còn đóng góp thêm thông tin cho ensemble cuối.

Trên nền các dự đoán OOF của bộ ba boosting, chúng tôi xây dựng một mô hình stacking với 14 396 mẫu meta và 44 đặc trưng. Kết quả so sánh được tóm tắt trong Bảng V6.

Chiến lược	**OOF F1_macro**	**Kaggle F1_macro**
Stacking	0.60173	**0.56944**
Voting_Top3	0.58899	–
Voting_All4	0.58899	–
XGBoost	0.583815	–
LightGBM	0.581083	–
CatBoost	0.573596	–
RandomForest	0.562498	–

Bảng V6. Hiệu suất OOF F1_macro của các mô hình và ensemble ở V6

Mô hình stacking đạt F1_macro OOF 0.60173 và F1_macro trên Kaggle 0.56944, là kết quả cao nhất trong tất cả các version. Khoảng cách giữa OOF (~0,602) và leaderboard (~0,569) khoảng 0,03, nhỏ hơn nhiều so với V3 hay V5. Điều này cho thấy việc chỉ giữ bộ ba boosting mạnh nhất, kết hợp với stacking gọn, là chiến lược phù hợp hơn so với ensemble quá nhiều mô hình hoặc can thiệp quá nhiều vào phân phối dữ liệu.

7) Tổng quan các phiên bản V1–V6

Bảng dưới đây tóm tắt ngắn gọn các version và điểm F1_macro trên Kaggle:

Version	**Mô tả ngắn**	**Kaggle F1_macro**
V1	Baseline RandomForest, tiền xử lý đơn giản	0.51468
V2	Thêm LightGBM, XGBoost, CatBoost; ensemble đơn các mô hình boosting	0.55079
V3	Thêm SVM, KNN, Naive Bayes; stacking meta trên 55 đặc trưng OOF	0.55555
V4	Tuning LGBM/XGB/Cat; ensemble 7 mô hình với trọng số gần đồng đều	0.54642
V5	Thử nghiệm class_weight/oversampling; ensemble 4 mô hình chính	0.50793
V6	Giữ "A-team" XGB+LGBM+Cat; voting có trọng số và stacking gọn	0.56944

Bảng Tóm tắt. Các phiên bản V1–V6 và F1_macro trên Kaggle

Nhìn vào bảng tóm tắt, có thể thấy điểm số không tăng đều qua từng version. Một số hướng tiếp cận (như ensemble 7 mô hình ở V4 hay cân bằng dữ liệu mạnh ở V5) làm điểm số giảm xuống, nhưng chính những kết quả này giúp chúng tôi điều chỉnh lại chiến lược và dẫn đến cấu hình V6 gọn hơn nhưng hiệu quả hơn. V6 là phiên bản cuối cùng được lựa chọn để tạo submission và sử dụng trong phần thảo luận, kết luận của bài báo.

IV. Kết quả và Thảo luận

A. Tổng hợp kết quả

Qua chuỗi thực nghiệm kéo dài qua 6 phiên bản, hệ thống phân loại thể loại nhạc của chúng tôi đã đạt được sự cải thiện đáng kể so với mốc xuất phát. Kết quả cuối cùng (V6) sử dụng kỹ thuật Stacking trên nền tảng các mô hình Gradient Boosting (XGBoost, LightGBM, CatBoost) đã chứng minh hiệu quả vượt trội.

Biểu đồ so sánh dưới đây (cần vẽ biểu đồ cột trong báo cáo) tóm tắt sự thăng tiến về chỉ số F1_macro trên tập Leaderboard: Baseline (V1): 0.51468; best performance (V6): 0.56944; mức tăng trưởng: +0.05476 điểm tuyệt đối ‘(~10.6% cải thiện).

B. Thảo luận về các yếu tố kỹ thuật

1. Sức mạnh của Gradient Boosting trên dữ liệu âm thanh dạng bảng Kết quả thực nghiệm khẳng định rằng với các đặc trưng âm học dạng bảng (danceability, energy, loudness...), các mô hình thuộc họ Gradient Boosting (LightGBM, XGBoost, CatBoost) hoạt động hiệu quả hơn hẳn so với các thuật toán cổ điển như SVM hay KNN. Khả năng xử lý các mối quan hệ phi tuyến và tự động trích xuất các ngưỡng quyết định (decision boundaries) phức tạp của cây quyết định là yếu tố then chốt giúp phân biệt các thể loại nhạc có tính chất chồng lấn (ví dụ: Rock vs. Alt Music).

2. Bài học từ sự đánh đổi giữa Đa dạng (Diversity) và Chất lượng (Quality) Sự sụt giảm hiệu suất ở phiên bản V4 (Ensemble 7 mô hình) là minh chứng cho thấy nguyên lý "Garbage In, Garbage Out" trong Ensemble Learning. Việc ép buộc kết hợp các mô hình yếu (Weak Learners với F1 < 0.45) vào hệ thống, dù đã tối ưu trọng số, vẫn gây nhiễu nhiều hơn là đóng góp thông tin hữu ích. Chiến lược "tinh gọn" ở V6 (chỉ giữ lại top 3 mô hình mạnh nhất) đã chứng minh rằng một ensemble nhỏ nhưng chất lượng sẽ tốt hơn một ensemble lớn nhưng hỗn tạp.

3. Tác động ngược của việc cân bằng dữ liệu nhân tạo Một phát hiện quan trọng từ thất bại của phiên bản V5 là sự nhạy cảm của phân phối dữ liệu. Trong bối cảnh bài toán này, việc can thiệp vào trọng số lớp (class_weight='balanced') hoặc oversampling đã làm méo mó phân phối xác suất thực tế (prior probability) của các thể loại nhạc. Mặc dù kỹ thuật này giúp mô hình nhận diện tốt hơn các lớp hiếm trong tập Train, nhưng lại khiến mô hình mất phương hướng khi gặp tập Test (vốn tuân theo phân phối tự nhiên). Điều này gợi ý rằng với dữ liệu âm nhạc thực tế, việc giữ nguyên tính chất tự nhiên của dữ liệu kết hợp với hàm mất mát phù hợp hiệu quả hơn là cố gắng cân bằng số lượng mẫu một cách cưỡng bức.

V. Kết luận và Hướng cải tiến

A. Tổng hợp kết quả

Trong nghiên cứu này, chúng tôi đã trình bày quy trình xây dựng hệ thống phân loại thể loại nhạc tự động dựa trên dữ liệu Music Genre Classification. Từ một mô hình Random Forest cơ sở, thông qua quy trình cải tiến lặp lại (iterative improvement) gồm tiền xử lý dữ liệu, lựa chọn mô hình, tối ưu hóa siêu tham số và kỹ thuật học kết hợp (Ensemble/Stacking), chúng tôi đã nâng cao độ chính xác F1_macro từ 0.514 lên 0.569.

Giải pháp cuối cùng là sự kết hợp của ba mô hình Gradient Boosting hàng đầu hiện nay, được tinh chỉnh để cân bằng giữa khả năng học trên tập dữ liệu huấn luyện và khả năng tổng quát hóa trên dữ liệu kiểm thử. Các thí nghiệm cũng chỉ ra những giới hạn của việc xử lý dữ liệu mất cân bằng và tầm quan trọng của việc lựa chọn thành phần cho hệ thống Ensemble.

B. Hướng cải tiến mô hình

Mặc dù đã đạt được kết quả khả quan, hệ thống vẫn còn dư địa để phát triển:

Khai thác dữ liệu văn bản (NLP): Hiện tại, các trường thông tin Artist Name và Track Name chưa được tận dụng triệt để. Việc áp dụng các kỹ thuật NLP (như TF-IDF, Word Embeddings hoặc BERT) để trích xuất đặc trưng ngữ nghĩa từ tên bài hát/nghệ sĩ có thể cung cấp thêm thông tin quan trọng để phân loại (ví dụ: từ khóa "Symphony" thường gợi ý nhạc cổ điển).

Áp dụng Deep Learning: Thử nghiệm các kiến trúc Mạng nơ-ron sâu (Deep Neural Networks) như TabNet (chuyên cho dữ liệu bảng) hoặc 1D-CNN (nếu có thể truy cập dữ liệu âm thanh thô hoặc spectrogram) để trích xuất các đặc trưng bậc cao mà mô hình cây có thể bỏ sót.

Tối ưu hóa Feature Selection: Sử dụng các kỹ thuật chọn lọc đặc trưng nâng cao như SHAP Values hoặc Permutation Importance để loại bỏ các đặc trưng nhiễu, giúp mô hình nhẹ hơn và tránh hiện tượng quá khớp tốt hơn nữa.

VI. Tham khảo

[1] Kaggle, Music Genre Classification Competition, 2022.
[2] T. Chen, C. Guestrin, “XGBoost: A Scalable Tree Boosting System”, Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016.
[3] G. Ke, Q. Meng, T. Finley, et al., “LightGBM: A Highly Efficient Gradient Boosting Decision Tree”, Advances in Neural Information Processing Systems (NeurIPS), 2017.
[4] A. Prokhorenkova, G. Gusev, A. Vorobev, et al., “CatBoost: Unbiased Boosting with Categorical Features”, Advances in Neural Information Processing Systems (NeurIPS), 2018.
[5] F. Pedregosa et al., “Scikit-learn: Machine Learning in Python”, Journal of Machine Learning Research, 12, 2825–2830, 2011.
[6] S. Sokolova, G. Lapalme, “A systematic analysis of performance measures for classification tasks”, Information Processing & Management, 45(4), 427–437, 2009.
[7] Tài liệu chính thức của Kaggle và các notebook tham khảo cộng đồng (truy cập cùng thời điểm triển khai mô hình) dùng làm nguồn ý tưởng cho chiến lược cross-validation, đánh giá mô hình và cách tổ chức pipeline huấn luyện.