Music Genre Analysis and Prediction Using Machine Learning Algorithms

PHÂN TÍCH VÀ DỰ ĐOÁN CÁC THỂ LOẠI ÂM NHẠC BẰNG CÁC THUẬT TOÁN MACHINE LEARNING

Lê Thanh Phát, Nguyễn Hữu Tri, Lư Hồng Phúc, Đỗ Duy Quý

GIỚI THIỆU

Bối cảnh

Khối lượng các bản nhạc được phát hành mỗi ngày là tăng, các thể loại âm nhạc mới cũng được sáng tạo đa dạng theo phong cách của nghệ sĩ.Do đó đòi hỏi hệ thống tự động phân loại để phục vụ tìm kiếm và gợi ý .

Mục tiêu chính:

- Xây dựng mô hình phân loại đa lớp (Multi-class Classification) dự đoán thể loại nhạc dựa trên các đặc trưng âm học và vật lý.
- Thước đo (Metric): Sử dụng F1-Macro làm chỉ số chính do dữ liệu bị mất cân bằng lớp nghiêm trọng, thay vì Accuracy.

DỮ LIỆU

"Dữ liệu: Kaggle "Music Genre Classification" (Train: 14,396 mẫu, Test: 3,600 mẫu)

Nguồn dữ liệu: Kaggle

https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques/data

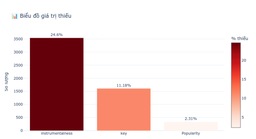

Biểu đồ cột mô tả các giá trị thiếu tập train

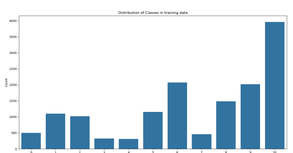

Biểu đồ phân phối các biến mục tiêu

PHƯƠNG PHÁP ĐỀ XUẤT

Raw Data → EDA → Feature Engineering → Preprocessing → Modeling → Evaluation → Prediction

1. Dữ liệu (Input Data)
- **Nguồn:** Kaggle Music Genre Classification
- **Kích thước:** Train (14,396), Test (3,600)
- **Đặc trưng:** Âm học (Danceability...) & Vật lý (Tempo...)
- **Đặc điểm:** Dữ liệu bảng, hỗn hợp số/phân loại

2. Phân tích & Khám phá (EDA)
- **Mất cân bằng:** Class 10 chiếm ưu thế
- **Missing:** Instrumentalness (~25%), Key, Popularity
- **Outliers:** Nhiều ở Tempo, Duration, Loudness
- **Tính chất:** Quan hệ phi tuyến, chồng lấn cao

3. Tiền xử lý & Feature Eng
- **Missing:** Điền Median (trung vị)
- **Scaler:** RobustScaler / StandardScaler (giảm nhiễu)
- **Feature Selection:** Loại bỏ Artist Name, Track Name
- **Chiến lược:** Giữ phân phối gốc (No Oversampling)

4. Xây dựng Mô hình & Đánh giá
- **Baseline:** Random Forest
- **Mô hình chính:** XGBoost, LightGBM, CatBoost
- **Metric:** F1-Macro (Tối ưu cho mất cân bằng)
- **Validation:** Stratified 5-Fold Cross-Validation

5. Học tập Tổng hợp (Ensemble)
- **Kỹ thuật:** Voting có trọng số & Stacking Meta-learner
- **Chiến lược 'A-Team':** Chỉ ghép 3 model mạnh nhất
- **Bài học:** Loại bỏ model yếu (KNN, SVM) khỏi Ensemble

6. Kết quả (Submission)
- **Kaggle F1-Score:** 0.56944 (Version 6)
- **Cải thiện:** +10.6% so với Baseline (0.514)
- **Kết luận:** Boosting + Stacking gọn nhẹ là tối ưu nhất

1.Phân tích & Khám phá dữ liệu (EDA)

Tên cột	Kiểu dữ liệu	Mô tả
Class	int (Categorical)	Thể loại nhạc (Biến mục tiêu - Target)
Danceability	float	Độ phù hợp để khiêu vũ/nhảy của bản nhạc
Energy	float	Mức độ năng lượng và cường độ của bản nhạc
Loudness	float	Độ lớn âm thanh trung bình (dB)
Tempo	float	Nhịp độ của bản nhạc (Beats per minute)
Valence	float	Sắc thái cảm xúc (tích cực/tiêu cực)
Acousticness	float	Độ mộc của âm thanh (không qua điện tử)
Instrumentalness	float	Tỷ lệ âm thanh nhạc cụ so với giọng hát
Duration	float	Thời lượng của bản nhạc (ms)
Key/Mode	int	Tông và điệu thức của bản nhạc

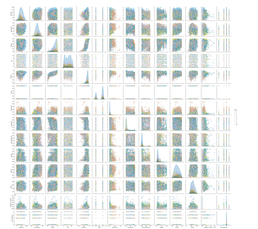

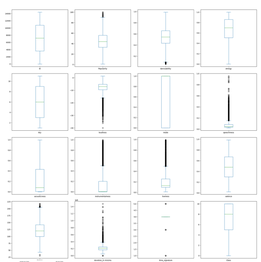

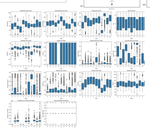

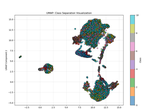

2. Quy trình tiền xử lý dữ liệu

Dữ Liệu Thô (14,396 mẫu) → Xử Lý Missing (Median & Drop) → Xử Lý Nhiễu (RobustScaler) → Chọn Lọc Đặc

4. Dữ liệu Sạch
- Sẵn sàng cho Kỹ thuật đặc trưng (Feature Engineering) và Mô hình hóa

4. Đánh giá & Valiadation

Mô tả thước đo và chiến lược để đảm bảo chất lượng mô hình.

a) Thước đo đánh giá

Thước đo chính (Kaggle): Sử dụng **F1-Macro** để đánh giá khách quan do dữ liệu bị **mất cân bằng lớp** nghiêm trọng.

Thước đo bổ sung (Nội bộ): Theo dõi thêm **Accuracy, Precision & Recall** để phân tích chi tiết các lớp bị nhận diện sai.

b) Chiến lược Validation

Phương pháp: Sử dụng **Stratified 5-Fold CV** .

Mục tiêu: Đảm bảo tỷ lệ các thể loại nhạc trong mỗi fold tương đồng với tập dữ liệu gốc.

Kiểm soát Overfitting: So sánh điểm **OOF** với Public Leaderboard.

c) Đánh giá chung

Kết quả: Mô hình **Gradient Boosting** (XGB, LGBM, Cat) vượt trội hoàn toàn so với SVM/KNN.

Phát hiện quan trọng:

- Kỹ thuật **Oversampling gây hại,** giảm tính tổng quát.
- **Stacking (V6)** gọn nhẹ mang lại kết quả tốt nhất (F1: 0.569).

3. Kỹ thuật đặc trưng

Tổng quan 3 bước chính trong quy trình lặp

a) Xử lý Dữ liệu thiếu

Thực trạng: Cột *instrumentalness* thiếu ~25% *key* và *popularity* cũng bị khuyết.

Giải pháp: Điền giá trị **Trung vị (Median)** (hạn chế ảnh hưởng của nhiễu.

Cân nhắc: Loại bỏ cột nếu tỷ lệ thiếu quá lớn gây nhiễu mô hình.

b) Chuẩn hóa & Ngoại lai

Vấn đề: *Tempo, Duration, Loudness* chứa nhiều giá trị ngoại lai (outliers).

Kỹ thuật: Sử dụng **RobustScaler** hoặc **StandardScaler**.

Mục tiêu: Giảm thiểu tác động tiêu cực của outliers lên các thuật toán nhạy cảm.

c) Chọn lọc Đặc trưng

Loại bỏ: Các trường định danh văn bản (*Artist Name, Track Name*).

Giữ lại: Tập trung vào nhóm đặc trưng **Âm học** (Acoustic features).

Lý do: Tăng khả năng tổng quát hóa, tránh mô hình học vẹt theo tên bài hát.

5. Mô hình hóa

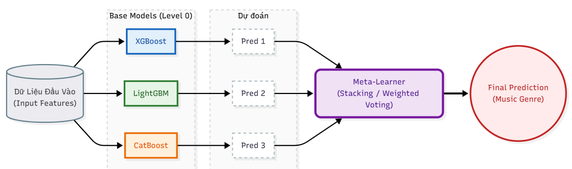

1. Khởi tạo & Tối ưu

Baseline: RF (0.514).
Nâng cấp: XGB, LGBM tăng F1 lên **0.551**.

2. Stacking (V3)

Mở rộng: Thêm SVM, KNN.
Kỹ thuật: Stacking Averaged Models.

3. Thử nghiệm (V4)

Sai lầm: Thêm model yếu.
Hậu quả: Nhiễu, giảm còn **0.546**.

4. Cân bằng (V5)

Vấn đề: Oversampling méo mó phân phối.
Kết quả: Overfitting nặng.

5. Chốt Hạ (V6)

Giải pháp: Top 3 (XGB+LGBM+Cat
Đỉnh cao: F1 đạt **0.56944.**

THỬ NGHIỆM VÀ KẾT QUẢ

Bảng: Quá trình cải tiến mô hình

Version	Mô tả ngắn	Kaggle F1_macro
V1	Baseline RandomForest, tiền xử lý đơn giản	0.51468
V2	Thêm LightGBM, XGBoost, CatBoost; ensemble đơn các mô hình boosting	0.55079
V3	Thêm SVM, KNN, Naive Bayes; stacking meta trên 55 đặc trưng OOF	0.55555
V4	Tuning LGBM/XGB/Cat; ensemble 7 mô hình với trọng số gần đồng đều	0.54642
V5	Thử nghiệm class_weight/oversampling; ensemble 4 mô hình chính	0.50793
V6	Giữ "A-team" XGB+LGBM+Cat; voting có trọng số và stacking gọn	0.56944

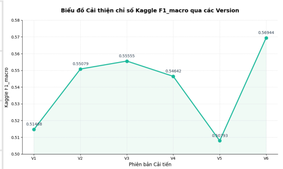

Nhận xét:

Quá trình phát triển mô hình trải qua biến động mạnh với ba giai đoạn: tăng trưởng ban đầu (V1-V3), suy giảm do tinh chỉnh chưa phù hợp (V4-V5), và đột phá tại phiên bản cuối. Đáng chú ý, việc can thiệp cân bằng dữ liệu tại V5 đã gây phản tác dụng khiến hiệu suất chạm đáy; tuy nhiên, chiến lược quay lại cốt lõi với bộ ba model mạnh nhất (XGB, LGBM, CatBoost) kết hợp Stacking gọn nhẹ ở V6 đã chứng minh hiệu quả vượt trội, đưa chỉ số F1 đạt đỉnh 0.56944. Đây chính là kiến trúc tối ưu nhất để triển khai thực tế."

Kết luận & Đánh giá

Mặc dù các phiên bản cải tiến liên tiếp đã đạt được độ chính xác khá tốt và ổn định, nhưng mô hình vẫn còn nhiều cơ hội để hoàn thiện.

- Hiệu quả tổng thể: Hệ thống đạt mức cải thiện 10.6%, nâng chỉ số F1-macro từ 0.514 (Baseline) lên 0.56944 (V6).
- Các mô hình Gradient Boosting (XGBoost, LightGBM, CatBoost) chứng minh khả năng vượt trội trong việc xử lý các đặc trưng âm thanh phức tạp so với các thuật toán cổ điển
- Việc cân bằng dữ liệu nhân tạo (Oversampling) và kết hợp quá nhiều mô hình yếu làm giảm khả năng tổng quát hóa của hệ thống.
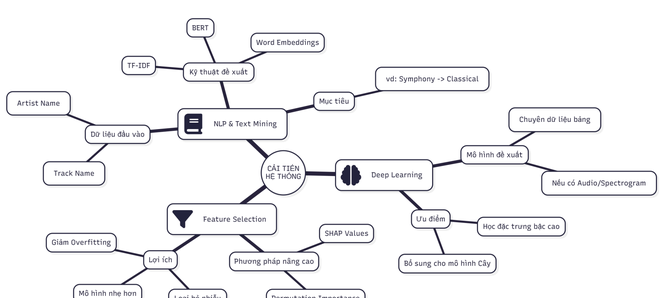
HƯỚNG CẢI TIẾN MÔ HÌNH