Kaggle Competition Project

Music Genre Classification

Thành viên: Nguyễn Hữu Tri
Lư Hồng Phúc
Lê Thanh Phát
Đỗ Duy Quý

Giảng viên: Đỗ Như Tài

December 1st, 2025

Mục lục

1.Phân tích bài toán và đặc trưng dữ liệu

2.Phương pháp và quá trình thử nghiệm

3. Kết quả và đánh giá

4. Hướng cải tiến mô hình

5. Tài liệu tham khảo

1.1 Phân tích bài toán

- **Bài toán:**
  - Phân loại đa lớp (Multi-class classification) trên tập dữ liệu "Music Genre Classification" từ Kaggle.
  - Triển khai các thuật toán học máy để dự đoán thể loại nhạc.

1.2 Đặc trưng dữ liệu

- Nguồn gốc: ***Music Genre Classification***
https://www.kaggle.com/competitions/shai-music-genre-classification/data

- Tổng quan:

Tập huấn luyện bao gồm **14.396** mẫu với 16 đặc trưng (features)

Mỗi mẫu được mô tả bằng 16 đặc trưng (features) được trích xuất từ tín hiệu âm thanh.

1.2 Phân tích dữ liệu

Các cột chính trong dữ liệu

Tên cột	Loại dữ liệu	Ý nghĩa
Class	int (Categorical)	Thể loại nhạc (Biến mục tiêu - Target)
Danceability	float	Độ phù hợp để khiêu vũ/nhảy của bản nhạc
Energy	float	Mức độ năng lượng và cường độ của bản nhạc
Loudness	float	Độ lớn âm thanh trung bình (dB)
Tempo	float	Nhịp độ của bản nhạc (Beats per minute)

Tên cột	Loại dữ liệu	Ý nghĩa
Valence	float	Sắc thái cảm xúc (tích cực/tiêu cực)
Acousticness	float	Độ mộc của âm thanh (không qua điện tử)
Instrumentalness	float	Tỷ lệ âm thanh nhạc cụ so với giọng hát
Duration	float	Thời lượng của bản nhạc (ms)
Key/Mode	int	Tông và điệu thức của bản nhạc

1.2 Phân tích dữ liệu

Các cột dữ liệu bị thiếu (train set)

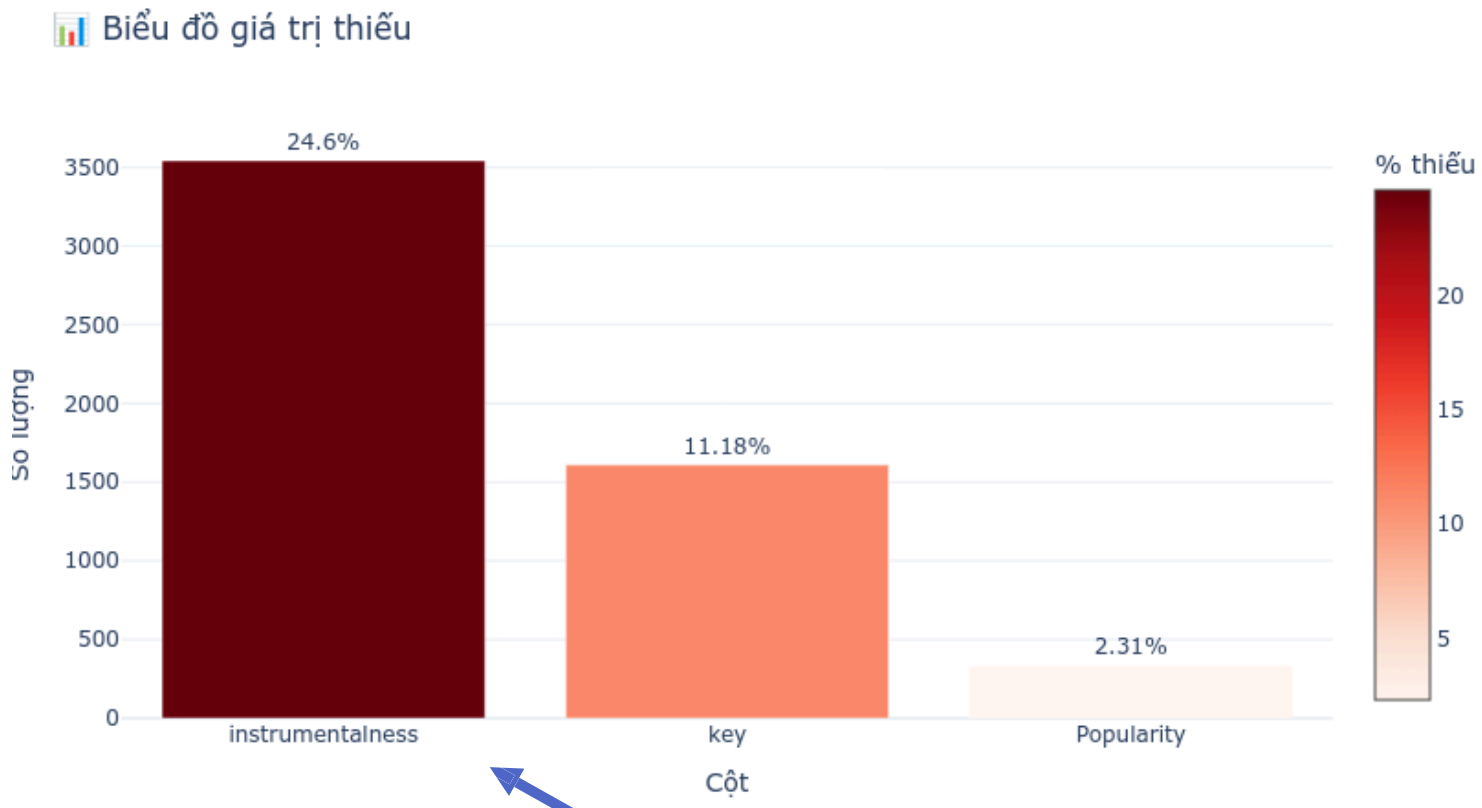

Phát hiện lượng lớn dữ liệu bị thiếu, đặc biệt là ở đặc trưng 'Instrumentalness'

1.2 Phân tích dữ liệu

Mất cân bằng dữ liệu

Class 10 chiếm ưu thế áp đảo. Sự mất cân bằng này khiến các mô hình cơ sở (Baseline) có xu hướng thiên vị lớp đa số.

1.2 Phân tích dữ liệu

Tương quan đặc trưng

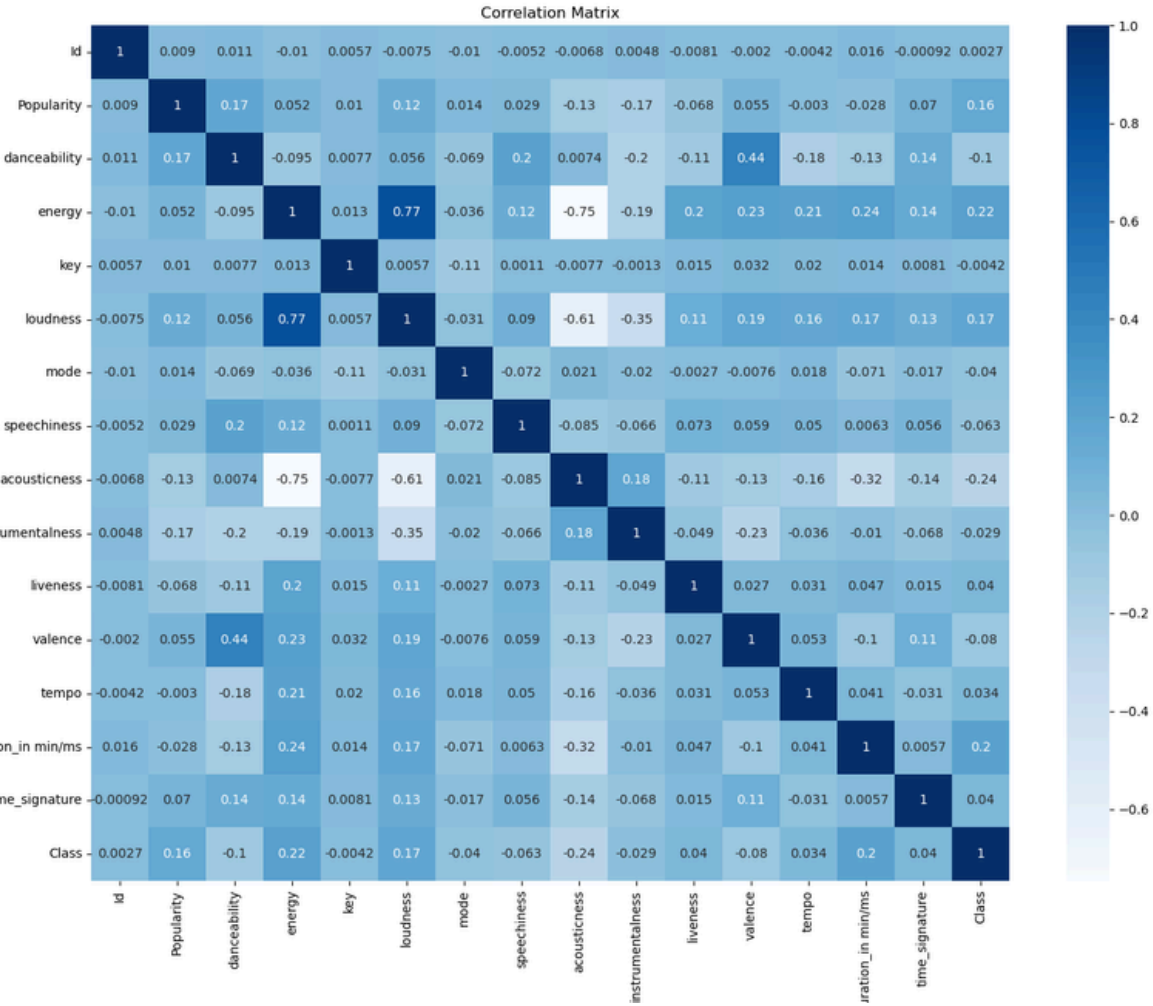

Tương quan dương: Energy và Duration có mối quan hệ thuận chiều đáng kể.

Tương quan âm: Acousticness (độ mộc) tỷ lệ nghịch với Energy/Loudness.

Tác động: 'Acousticness' là tín hiệu quan trọng để phân biệt nhạc điện tử và nhạc cụ mộc.

1.2 Phân tích dữ liệu

Phân tích đơn biến

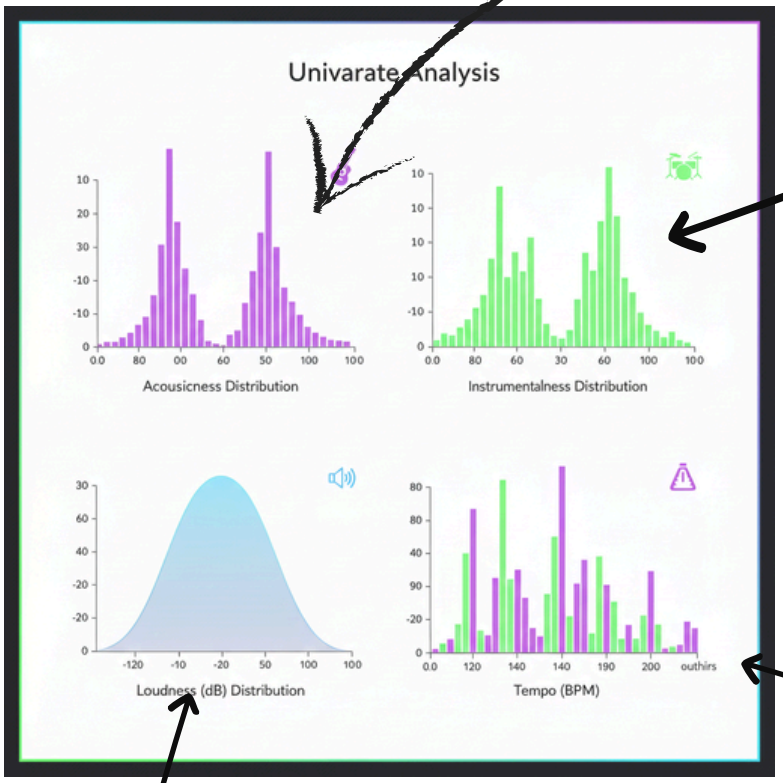

Độ Acousticness & Instrumentalness: Phần lớn các bản nhạc rơi vào hai thái cực—hoặc rất acoustic/không lời hoặc rất ít acoustic/có lời hát.

Nhịp độ/Tempo (Đa đỉnh): Dữ liệu rất đa dạng về tốc độ, với các nhóm lớn tập trung ở nhiều nhịp độ khác nhau

Độ Loudness (Phân phối chuẩn): Âm lượng của các bản nhạc chủ yếu tập trung quanh mức trung bình (khoảng -10 đến -20 dB).

1.2 Phân tích dữ liệu

Phân tích đơn biến

Các đặc điểm này củng cố tính phân cực của tập dữ liệu (nhất là ở Energy và Valence), cho thấy đây là sự pha trộn của ít nhất hai loại hình âm nhạc khác nhau.

1.2 Phân tích dữ liệu

Phân tích đa biến

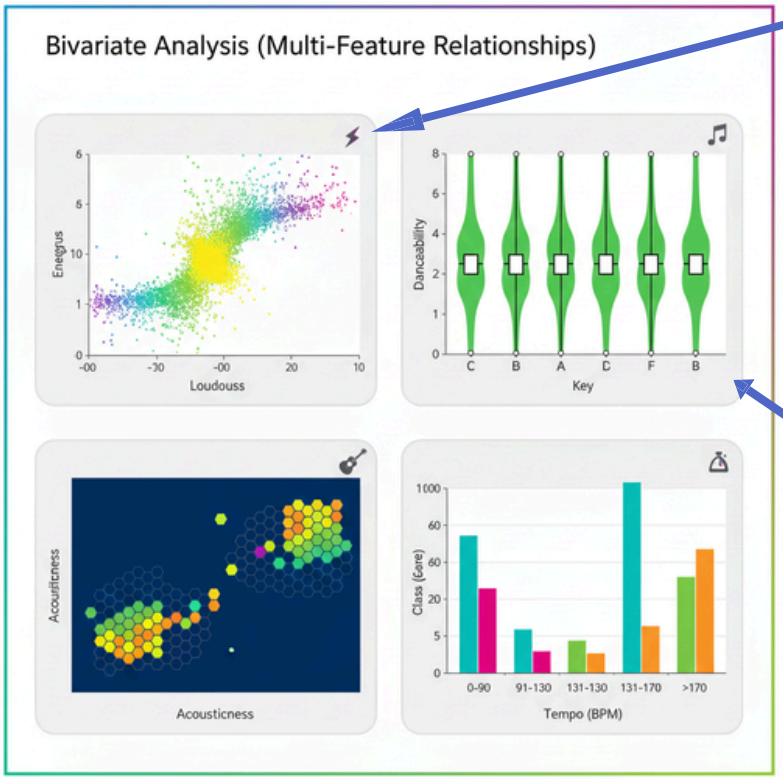

Loudness có mối quan hệ tương quan dương trực tiếp với Năng lượng (Energy). Các bản nhạc càng to thì càng có năng lượng cao, và ngược lại.

Mức độ Danceability (tính nhảy múa) gần như không thay đổi đáng kể giữa các khóa nhạc (Key) khác nhau.

2.1 Phương pháp triển khai

- Xử lí dữ liệu:
  - làm sạch,
  - xử lý ngoại lệ,
  - bổ sung đặc trưng mới và
  - mã hóa – chuẩn hóa biến

- Phương pháp triển khai:
  - ***Stacking Ensemble***

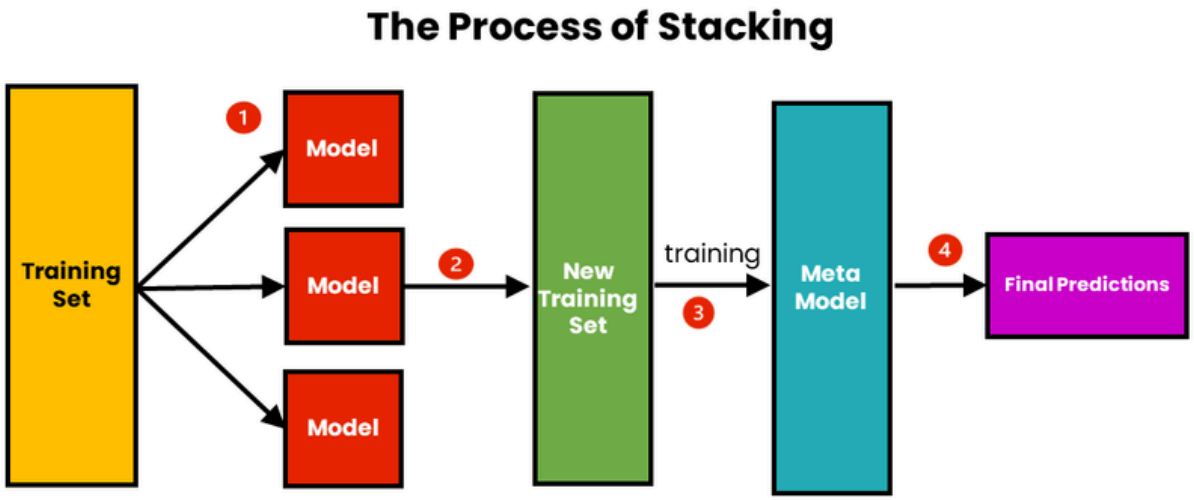

2.2 Quá trình thử nghiệm

- ***Baseline:*** *Dữ liệu sau khi tiền xử lý đơn giản được đưa trực tiếp vào mô hình Random Forest.*

Model	Accuracy	Precision macro	Recallmacro	F1 macro	Kaggle F1 macro
Random Forest Fold4	0.51	0.57957	0.560407	0.563415	–
Random Forest (submit)	–	–	–	–	0.51468

2.2 Quá trình thử nghiệm

Phiên bản V2 – Thêm các mô hình boosting

- *Sau khi thiết lập Baseline (Random Forest) ở V1, mục tiêu của V2 là khai thác sức mạnh của các thuật toán nâng cao hơn để xử lý các mối quan hệ phi tuyến phức tạp trong dữ liệu.*

Model	Mean CV F1	Std CV F1	OOF F1
XGBoost	0.580747	0.00583	0.580819
LightGBM	0.580455	0.003037	0.580571
CatBoost	0.571812	0.007168	0.571978
RandomForest	0.556624	0.005795	0.556995

2.2 Quá trình thử nghiệm

***Version 3.* Mở rộng Mô hình Cơ sở (Base Models)**

Ngoài 4 mô hình ở V2 (Random Forest, LightGBM, XGBoost, CatBoost), V3 đã bổ sung thêm 3 mô hình học máy truyền thống để tăng tính đa dạng:

- SVM
- KNN
- Naive Bayes

Triển khai Stacking Meta

Đây là điểm khác biệt cốt lõi của V3:

-
- Tạo Tập Meta-Training: Các dự đoán OOF (Out-Of-Fold) từ nhiều mô hình được ghép lại thành một tập dữ liệu huấn luyện mới (Meta Train).
- Kích thước: Tập Meta Train có kích thước 14,396 mẫu với 55 đặc trưng (features) mới.
- Mô hình Stacking: Một mô hình Stacking (Meta Model) được huấn luyện trên không gian đặc trưng mới này để học cách kết hợp các dự đoán của các mô hình cơ sở.

2.2 Quá trình thử nghiệm

Version3 *tăng cường sự đa dạng của mô hình cơ sở và sử dụng chiến lược Stacking Meta để cải thiện hiệu suất so với V2.*

Model	F1 macro	Accuracy	Precision macro	Recall macro
CatBoost	0.575677	0.549944	0.607976	0.579318
LightGBM	0.575371	0.542025	0.593165	0.573695
XGBoost	0.571738	0.523688	0.581239	0.570517
Random Forest	0.559542	0.525841	0.589477	0.558327
SVM	0.545173	0.517575	0.575545	0.545282
KNN	0.51726	0.482008	0.530837	0.522345
Naive Bayes	0.426159	0.371562	0.425248	0.515441

2.2 Quá trình thử nghiệm

- ***Tinh chỉnh tham số***
  - *Các mô hình được tuning chuyên sâu: XGBoost, LightGBM, và CatBoost[1].*
  - *Việc tuning giúp các mô hình Boosting này cải thiện nhẹ về hiệu suất F1-macro trên tập CV*
- ***Chiến lược Emsemble***
  - *Mô hình tham gia: V4 thử nghiệm một Ensemble kết hợp cả 7 mô hình (XGBoost, LightGBM, CatBoost, Random Forest, SVM, KNN, Naive Bayes).*
  - *Trọng số: Tối ưu trọng số cho ensemble 7 mô hình, kết quả là trọng số gần bằng nhau cho tất cả*

2.2 Quá trình thử nghiệm

- ***Version 4:***
  - *V4 thử nghiệm một Ensemble kết hợp cả 7 mô hình có sẵn từ V3*
  - *Trọng số tối ưu cho Ensemble 7 mô hình được tìm thấy là gần bằng nhau cho tất cả*

Mô hình	Trọng số tối ưu
LightGBM	0.1429
XGBoost	0.1429
CatBoost	0.1429
Random Forest	0.1429

Mô hình	Trọng số tối ưu
SVM	0.1429
KNN	0.1429
NaiveBayes	0.1429
Ensemble V4 (CV F1_macro)	**0.5741**

2.2 Quá trình thử nghiệm

- ***Version 5:***
  - ***Mục tiêu chính của V5 là cải thiện khả năng nhận diện (Recall) đối với các lớp thiểu số bằng cách can thiệp vào phân phối dữ liệu, với kỳ vọng tăng chỉ số F1-macro tổng thể.***
  - ***V5 thử áp dụng các kỹ thuật cân bằng dữ liệu:***
    - ***Cân bằng trọng số lớp (class_weight): Sử dụng các tham số trọng số lớp.***
    - ***Oversampling (Tăng cường mẫu): Thử nghiệm các kỹ thuật oversampling để xử lý mất cân bằng lớp.***

2.2 Quá trình thử nghiệm

Bảng hiệu suất stacking ở V3

Model	CV_F1
LightGBM	0.56953
XGBoost	0.569737
CatBoost	0.569048
RandomForest	0.547661

Bảng hiệu suất stacking ở V5

Mô hình	Trọng số
LightGBM	0.25
XGBoost	0.25
CatBoost	0.25
RandomForest	0.25
Ensemble V5 (CV F1_macro)	**0.57869**

Việc sử dụng kỹ thuật Stacking (kết hợp nhiều mô hình) đã mang lại cải thiện đáng kể về mặt hiệu suất F1-score so với hiệu suất tốt nhất của mô hình đơn lẻ (0.57869 so với 0.569737 của XGBoost), cho thấy đây là một chiến lược hiệu quả để tối ưu hóa kết quả.

2.2 Quá trình thử nghiệm

6) Phiên bản V6 – "A-team" boosting và stacking gọn
V6 được thiết kế dựa trên kinh nghiệm rút ra từ các version trước:

Chiến lược	OOF F1_macro	Kaggle F1_macro
Stacking	0.60173	**0.56944**
Voting_Top3	0.58899	–
Voting_All4	0.58899	–
XGBoost	0.583815	–
LightGBM	0.581083	–
CatBoost	0.573596	–
RandomForest	0.562498	–

3. Kết quả và đánh giá

- ***Tổng hợp + Kết quả kaggle:***

Điểm số khi submit tương ứng với từng lần cải tiến	
Version1	0.51468
Version2	0.55079
Version3	0.55555
Version4	0.54642
Version5	0.50793
Version6	0.56944

V6 là phiên bản cuối cùng được lựa chọn để tạo submission và sử dụng trong phần thảo luận, kết luận của bài báo.

4. Hướng cải tiến mô hình

- ***Tồn tại và hướng cải tiến***

1. *Khai thác Dữ liệu Văn bản (NLP)*
2. *Áp dụng Deep Learning*
3. *Tối ưu hóa Feature Selection (Chọn lọc Đặc trưng)*

5. Tài liệu tham khảo

- **Tham khảo**

[1] Kaggle, Music Genre Classification Competition, 2022.

[2] T. Chen, C. Guestrin, "XGBoost: A Scalable Tree Boosting System", Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016.

[3] G. Ke, Q. Meng, T. Finley, et al., "LightGBM: A Highly Efficient Gradient Boosting Decision Tree", Advances in Neural Information Processing Systems (NeurIPS), 2017.

[4] A. Prokhorenkova, G. Gusev, A. Vorobev, et al., "CatBoost: Unbiased Boosting with Categorical Features", Advances in Neural Information Processing Systems (NeurIPS), 2018.

THANK YOU FOR LISTENING